파이썬 라이브러리를 활용한 데이터 분석

10장 데이터 집계와 그룹 연산

2020.07.09号 2h

10장 데이터 집계와 그룹 연산


圆0目型測

.5h

데이터 집계

p 396

• 배열에서 스칼라 값을 만들어 내는 모든 데이터 변환 작업



그룹을 나눈 후 한 컬럼에 하나의 함수 적용

• 메소드 agg('적용함수명')

```
In [99]: |tips = pd.read_csv('examples/tips.csv')
          # Add tip percentage of total bill
           tips['tip_pct'] = tips['tip'] / tips['total_bill']
           tips[:6]
Out[99]:
                 16.99 1.01
                                No Sun Dinner
                                                  2 0.059447
                                                  3 0.160542
                 10.34 1.66
                                    Sun Dinner
            2
                 21.01 3.50
                                    Sun Dinner
                                                  3 0.166587
                 23.68 3.31
                                    Sun Dinner
                                                  2 0.139780
            3
                 24.59 3.61
                                    Sun Dinner
                                                  4 0.146808
                 25.29 4.71
                                                  4 0.186240
            5
                                    Sun Dinner
In [100]: grouped = tips.groupby@['day', 'smoker
In [101]: grouped_pct = grouped['tip_pct']
          grouped_pct.agg('mean')
Out [101]:
          day
                 smoker
          Fri
                 No
                           0.151650
                           0.174783
                 Yes
                            0.158048
           Sat
                 No
                           0.147906
                 Yes
                 No
                           0.160113
           Sun
                 Yes
                           0.187250
           Thur
                 No
                           0.160298
                           0.163863
                 Yes
           Name: tip pct, dtype: float64
```

o n

그룹핑 후 값인 팁 비율에 여러 함수 적용

- 함수가 열명
 - def peak_to_peak(arr):
 - return arr.max() arr.min()

- 함수의 열명 설정
 - (name, function), ...



PYTHON PROGRAMMING

여러 컬럼에 동일 함수 적용

- In [108]: functions = ['count', 'mean', 'max']
 result = grouped[['tip_pct', 'total_bill']].agg(functions)
 result
- 칼럼 tip_pct와 total_bill에 3 개의 함수 적용
- 컬럼명 바꾸기
 - ('컬럼명', '메소드')

tip_pct

```
In [114]: #ftuples = [('Durchschnitt', 'mean'), ('Abweichung', np.var)]
ftuples = [('평균', 'mean'), ('분산', np.var)]
grouped[['tip_pct', 'total_bill']].agg(ftuples)
```

total bill

Out[114]:

		평균	분산	평균	분산
day	smoker				
Fri	No	0.151650	0.000791	18.420000	25.596333
	Yes	0.174783	0.002631	16.813333	82.562438
Sat	No	0.158048	0.001581	19.661778	79.908965
	Yes	0.147906	0.003767	21.276667	101.387535
Sun	No	0.160113	0.001793	20.506667	66.099980
	Yes	0.187250	0.023757	24.120000	109.046044
Thur	No	0.160298	0.001503	17.113111	59.625081
	Yes	0.163863	0.001551	19.190588	69.808518

		tip_pct	:		total_bill				
		count	mean	max	count	mean	max		
day	smoker								
Fri	No	4	0.151650	0.187735	4	18.420000	22.75		
	Yes	15	0.174783	0.263480	15	16.813333	40.17		
Sat	No	45	0.158048	0.291990	45	19.661778	48.33		
	Yes	42	0.147906	0.325733	42	21.276667	50.81		
Sun	No	57	0.160113	0.252672	57	20.506667	48.17		
	Yes	19	0.187250	0.710345	19	24.120000	45.35		
Thur	No	45	0.160298	0.266312	45	17.113111	41.19		
	Yes	17	0.163863	0.241255	17	19.190588	43.11		
		•••••			•				

In [109]: result['tip_pct']

Out[109]:

Out[108]:

		count	mean	max
day	smoker			
Fri	No	4	0.151650	0.187735
	Yes	15	0.174783	0.263480
Sat	No	45	0.158048	0.291990
	Yes	42	0.147906	0.325733
Sun	No	57	0.160113	0.252672
	Yes	19	0.187250	0.710345
Thur	No	45	0.160298	0.266312
	Yes	17	0.163863	0.241255

Python

DATION DECODARATING

'size' : 'sum'})

칼럼마다 다른 함수 적용 [115]:

• 사전 형식

```
- { '칼럼명1': [함수1, 함수2],'칼럼명2': [함수3, 함수4],'칼럼명3': [함수5, 함수6], ...
```

```
tip
                  size
day smoker
 Fri
        No
             3.50
        Yes
             4.73
                   31
             9.00 115
        No
 Sat
        Yes 10.00 104
             6.00 167
Sun
        Yes
             6.50
                   49
             6.70 112
Thur
        Yes 5.00
```

In [115]: grouped.agg({ 'tip' : np.max

Out[116]:

		tip_pct				size
		min	max	mean	std	sum
day	smoker					
Fri	No	0.120385	0.187735	0.151650	0.028123	9
	Yes	0.103555	0.263480	0.174783	0.051293	31
Sat	No	0.056797	0.291990	0.158048	0.039767	115
	Yes	0.035638	0.325733	0.147906	0.061375	104
Sun	No	0.059447	0.252672	0.160113	0.042347	167
	Yes	0.065660	0.710345	0.187250	0.154134	49
Thur	No	0.072961	0.266312	0.160298	0.038774	112
	Yes	0.090014	0.241255	0.163863	0.039389	40

색인되지 않은 형태로 집계된 데이터 변환하기

• 옵션 as_index=False

In [119]: tips.groupby(['day', 'smoker'], as_index=False).mean() Out[119]: day smoker total bill size tip_pct 0 Fri No 18.420000 2.812500 2.250000 0.151650 1 Yes 16.813333 2.714000 2.066667 0.174783 No 19.661778 3.102889 2.555556 0.158048 Sat Yes 21.276667 2.875476 2.476190 0.147906 Sun No 20.506667 3.167895 2.929825 0.160113 Sun Yes 24.120000 3.516842 2.578947 0.187250 Thur No 17.113111 2.673778 2.488889 0.160298 7 Thur Yes 19.190588 3.030000 2.352941 0.163863 In [120]: tips.groupby(['day', 'smoker'], as_index=True).mean() Out[120]: total_bill

size tip_pct day smoker No 18.420000 2.812500 2.250000 0.151650 Fri Yes 16.813333 2.714000 2.066667 0.174783 No 19.661778 3.102889 2.555556 Sat 0.158048 Yes 21.276667 2.875476 2.476190 0.147906 Sun **No** 20.506667 3.167895 2.929825 0.160113 Yes 24.120000 3.516842 2.578947 0.187250 17.113111 2.673778 2.488889 Thur 0.160298 Yes 19.190588 3.030000 2.352941 0.163863

ython


10장 데이터 집계와 그룹 연산

Apply: 일반적인 분리-적용-병합

2h

메소드 apply()

- 객체를 여러 조각인 그룹으로 나누고,
- 전달된 함수를 각 그룹에 일괄 적용한 후 이를 다시 합쳐, 데이터프레임 (또는 시리즈) 반환



PYTHON PROGRAMMING

그룹별 상위 tip_pct

상위 6개

- 흡연 여부에 따른 상위 5개
- 메소드 apply(함수)에서
 - 함수가 추가적인 인자가 필요 In [122]: tips.groupby('smoker').apply(top)
 - 함수 이름 뒤에 붙여서 넘김

In [121]:	<pre>def top(df, n=5, column='tip_pct'):</pre>
	return df.sort_values(by=column)[-n:]
	top(tips, n=6)

	total_bill	tip	smoker	day	time	size	tip_pct
109	14.31	4.00	Yes	Sat	Dinner	2	0.279525
183	23.17	6.50	Yes	Sun	Dinner	4	0.280535
232	11.61	3.39	No	Sat	Dinner	2	0.291990
67	3.07	1.00	Yes	Sat	Dinner	1	0.325733
178	9.60	4.00	Yes	Sun	Dinner	2	0.416667
172	7.25	5.15	Yes	Sun	Dinner		0.710345

total bill tip

Out[122]:


Out[121]:

In [123]:	tips.groupby(['smoker', 'day']).apply(top, n=1, column='total_bill')									
Out[123]:					tip	smoker	day	time	size	tip_pct
ſ	smoker	day								
	No	Fri	94	22.75	3.25	No	Fri	Dinner	2	0.142857
		Sat	212	48.33	9.00	No	Sat	Dinner	4	0.186220
		Sun	156	48.17	5.00	No	Sun	Dinner	6	0.103799
		Thur	142	41.19	5.00	No	Thur	Lunch	5	0.121389
	Yes	Fri	95	40.17	4.73	Yes	Fri	Dinner	4	0.117750
		Sat	170	50.81	10.00	Yes	Sat	Dinner	3	0.196812
		Sun	182	45.35	3.50	Yes	Sun	Dinner	3	0.077178
		Thur	197	43.11	5.00	Yes	Thur	Lunch	4	0.115982

smoker								
No	88	24.71	5.85	No	Thur	Lunch	2	0.236746
	185	20.69	5.00	No	Sun	Dinner	5	0.241663
	51	10.29	2.60	No	Sun	Dinner	2	0.252672
	149	7.51	2.00	No	Thur	Lunch	2	0.266312
	232	11.61	3.39	No	Sat	Dinner	2	0.291990
Yes	109	14.31	4.00	Yes	Sat	Dinner	2	0.279525
	183	23.17	6.50	Yes	Sun	Dinner	4	0.280535
	67	3.07	1.00	Yes	Sat	Dinner	1	0.325733
	178	9.60	4.00	Yes	Sun	Dinner	2	0.416667
	172	7.25	5.15	Yes	Sun	Dinner	2	0.710345

smoker day

메소드 describe() 활용



In [129]: tips.groupby('smoker', group_keys=False).apply(top)

Out[129]:

• 옵션 group_keys=False

그룹 색인 생략하기

- 색인을 하지 않고 열에 남음

	total_bill	tip	smoker	day	time	size	tip_pct
88	24.71	5.85	No	Thur	Lunch	2	0.236746
185	20.69	5.00	No	Sun	Dinner	5	0.241663
51	10.29	2.60	No	Sun	Dinner	2	0.252672
149	7.51	2.00	No	Thur	Lunch	2	0.266312
232	11.61	3.39	No	Sat	Dinner	2	0.291990
109	14.31	4.00	Yes	Sat	Dinner	2	0.279525
183	23.17	6.50	Yes	Sun	Dinner	4	0.280535
67	3.07	1.00	Yes	Sat	Dinner	1	0.325733
178	9.60	4.00	Yes	Sun	Dinner	2	0.416667
172	7.25	5.15	Yes	Sun	Dinner	2	0.710345


In [128]: tips.groupby('smoker').apply(top)

Out[128]:

		total_bill	tip	smoker	day	time	size	tip_pct
smoker								
No	88	24.71	5.85	No	Thur	Lunch	2	0.236746
	185	20.69	5.00	No	Sun	Dinner	5	0.241663
	51	10.29	2.60	No	Sun	Dinner	2	0.252672
	149	7.51	2.00	No	Thur	Lunch	2	0.266312
	232	11.61	3.39	No	Sat	Dinner	2	0.291990
Yes	109	14.31	4.00	Yes	Sat	Dinner	2	0.279525
	183	23.17	6.50	Yes	Sun	Dinner	4	0.280535
	67	3.07	1.00	Yes	Sat	Dinner	1	0.325733
	178	9.60	4.00	Yes	Sun	Dinner	2	0.416667
	172	7.25	5.15	Yes	Sun	Dinner	2	0.710345

등 간격 버킷 분석

• 난수에서 4등분한 버킷의 수, 최대, 평균, 최소 구하기



PYTHON PROGRAMM

수가 같은 버킷 분석

- 표본 변위치 기반
 - 크기가 같은 버킷
 - qcut()
- 옵션 labels=False
 - 구간이 없이 정수 인덱스로

```
In [148]: # Return quantile numbers
          #grouping = pd.gcut(frame.data1, 10, labels=False)
          grouping = pd.qcut(frame.data1, 10)
          grouped = frame.data2.groupby(grouping)
          grouped.apply(get stats)
Out[148]: data1
                                       -3.018842
          (-3.647, -1.272]
                             min
                                        2.146716
                             max
                                       100,000000
                             count
                                        -0.072422
                             mean
          (-1.272, -0.87]
                                        -2.641014
                             min_
                                         . . .
          (0.833, 1.242]
                                        -0.004802
                             mean
          (1.242, 3.526)
                             min
                                       -2.494075
```

max

Name: data2, Length: 40, dtype: float64

count mean

1.716892

100.000000

-0.079520

```
In [142]: # Return quantile numbers
           grouping = pd.qcut(frame.dat<u>a1, 10, lab</u>els=False
           grouped = frame.data2.groupby(grouping)
           grouped.apply(get stats)
Out[142]:
          data1
           0
                  min
                             -2.434322
                              2.465567
                  max
                           100.000000
                  count
                  mean
                             -0.004318
                            -2.909373
                  min
                               . . .
                             -0.054800
           8
                  mean
                  min
                             -1.872121
                             2.615416
                  max
                            100.000000
                  count
                              0.127347
                  mean
           Name: data2, Length: 40, dtype: float64
```

grouped.apply(get_stats).unstack()

Out[141]:

	min	max	count	mean
data1				
0	-2.434322	2.465567	100.0	-0.004318
1	-2.909373	2.531127	100.0	-0.156638
2	-2.480208	2.275784	100.0	-0.011883
3	-3.548824	2.374374	100.0	0.024064
4	-2.128789	2.419003	100.0	0.039156
5	-1.995456	2.492224	100.0	0.072292
6	-2.372214	3.366626	100.0	0.025465
7	-2.186301	1.861150	100.0	0.002594
8	-2.748685	2.452835	100.0	-0.054800
9	-1.872121	2.615416	100.0	0.127347

결측 치 채우기

메소드 fillna()

```
In [149]: s = pd.Series(np.random.randn(6))
          s[::2] = np.nan
Out[149]:
                    NaN
              1.207528
                    NaN
              -0.998061
                    NaN
              -1.356067
          dtype: float64
          s.fillna(s.mean())
In [150]:
Out[150]: 0
              -0.382200
              1.207528
              -0.382200
            -0.998061
              -0.382200
              -1.356067
          dtype: float64
```

그룹별 평균 구하기

- 결측치를 그대로 그룹별 평균 구하기
 - 그룹을 외부 배열 사용

```
In [154]: states = ['Ohio', 'New York', 'Yermont', 'Florida',
                   'Oregon', 'Nevada', 'California', 'Idaho']
          data = pd.Series(np.random.randn(8), index=states)
          data[['Vermont', 'Nevada', 'Idaho']] = np.nan
          data
Out[154]: Ohio
                      -1.765102
          New York
                     2.575626
          Vermont
                            NaN
          Florida
                      -1.772692
          Oregon
                      -0.408560
          Nevada
                            NaN
          California -1.437569
          Idaho
                            NaN
          dtype: float64
In [155] | group_key = ['East'] * 4 + ['West'] * 4
          data.groupby(group_key).mean()
Out[155]: Fast -0.320723
          West -0.923065
          dtype: float64
```

그룹별로 na 채우기

• 그룹별 평균을 na로 채우기

```
그룹에 특정 값 지정
                                         In [156]:
                                                   fill mean = lambda g: g.fillna(g.mean())
                                                   data.groupby(group_key).apply(fill_mean)
  - 사전 형식으로
                                         Out[156]: Ohio
                                                                -1.765102
        fill_func = lambda g:
                                                   New York
                                                                 2.575626
                                                               -0.320723
                                                   Vermont
          g.fillna(fill_values[g.name])
                                                                -1.772692
                                                   Florida
                                                   Oregen
                                                                -0.408560
                                                   Nevada
                                                                -0.923065
                                                   California
                                                                -1.437569
                                                    Idaho .
                                                                -0.923065
Out[154]:
         Ohio
                      -1.765102
                                                   dtype: float64
          New York
                       2.575626
          Vermont
                           NaN
         Florida
                      -1.772692
                                            11581:
                                                   fill_values = { 'East': 0.5, 'West': -1}
         Oregon
                      -0.408560
                                                   fill_func = lambda g: g.fillna(fill_values[g.name])
                           NaN
          Nevada
                                                   data.groupby(group_key).apply(fill_func)
                      -1.437569
         California
                                         Out[158]:
          Idaho
                           NaN
                                                   Ohio
                                                                -1.765102
          dtype: float64
                                                   New Yor
                                                                 2.575626
                                                                0.500000
                                                   Vermont
                                                   Florida
                                                                -1.772692
                                                   Oregon
                                                                -0.408560
                                                   Nevada
                                                                -1.000000
                                                   California
                                                                -1.437569
                                                   Idaho
                                                                -1.000000
                                                   dtype: float64
```

결측치 처리에 따른 결과 비교

• 결측치 처리 후 비교

```
In [164]: group_key = ['East'] * 4 + ['West'] * 4
    data.groupby(group_key).mean()

Out[164]: East    -0.320723
    West    -0.923065
    dtype: float64

In [165]: fill_values = {'East': 0.5, 'West': -1}
    fill_func = lambda g: g.fillna(fill_values[g.name])
    data2 = data.groupby(group_key).apply(fill_func)
    data2.groupby(group_key).mean()

Out[165]: East    -0.115542
    West    -0.961532
    dtype: float64
```

PYTHON PROGRAMMING

트럼프 카드 예시

- 카드 덱
 - 총 13*4 = 52개
 - _ 모양
 - 4개



```
In [167]: # Hearts, Spades, Clubs, Diamonds
           suits = ['H', 'S', 'C', 'D']
           card_val = (list(range(1, 11)) + [10] * 3) * 4
           base names = ['A'] + list(range(2, 11)) + ['J', 'K', 'Q']
           cards = []
           for suit in ['H', 'S', 'C', 'D']:
              cards.extend(str(num) + suit for num in base names)
           deck = pd.Series(card_val, index=cards)
           deck
Out[167]: AH
           2H
                   2
           3Н.
           4H
                   5
           5H
           9D
                  9
                  10
           10D
                  10
           JD
                  10
           KD
           ΩD
                  10
          Length: 52, dtype: int64
```

In [168]: deck[:13] Out[168]: AH 2H 3Н 6H

7H 8Н

9H

10H JΗ

KH

QH

9 10 10 10 thon 10 dtype: int64


카드 뽑기

- 카드 5장 랜덤하게 뽑기
- 각 셋 그림별 2장 뽑기
 - deck.groupby(get_suit)
 - 인덱스의 마지막 문자
 인 카드의 종류(C, D,
 H, S)에 따라 그룹핑
 - 그림 첫 글자 보이기/안 보이기
 - group_keys=False

```
In [169]: def draw(deck, n=5):
              return deck.sample(n)
          draw(deck)
Out[169]: JS
                10
                10
          JC
                10
          AS
                1
          9H
          dtype: int64
In [180]: [cards[:12], cards[13:25], cards[26:38], cards[-12:]]
Out[180]: [['AH', '2H', '3H', '4H', '5H', '6H', '7H', '8H', '9H', '10H', 'JH', 'KH'],
                        '38', '48',
                                    '58', '68', '78', '88', '98', '108',
           ['AC', '2C', '3C', '4C', '5C', '6C', '7C', '8C', '9C', '10C', 'JC', 'KC'],
           ['2D', '3D', '4D', '5D', '6D', '7D', '8D', '9D', '10D', 'JD', 'KD', 'QD']]
In [181]: get_suit = lambda card: card[-1] # /ast /etter is suit
          deck.groupby(get suit).apply(draw, n=2)
Out[181]: C 7C
              30
                    3
             ΩD
                   10
             JD
                   10
             7H
                    - 7
             JH
                   10
          S KS
                   10
             78
                    7
          dtype: int64
In [182]: deck.groupby(get suit, group keys=False).apply(draw, n=2)
Out[182]: 60
                  6
          20
                  2
          10D
                 10
          3D
          5H
          2H
          108
                 10
          28
          dtype: int64
```

가중 평균

numpy.average(a, axis=None, weights=None, returned=False)



	Number (Grades)	Weighting Factor (w)	Number X Weighting factor (w)
Quizzes	82 ×	0.2 =	16.4
Exam	90 ×	0.35 =	31.5
Term Paper	76 ×	0.45 =	34.2

Weighted Mean Formula

Weighted mean =
$$\frac{\sum_{i=1}^{n} weight_{n} \times x_{n}}{\sum_{i=1}^{n} weight_{n}}$$

그룹별 가중 평균 구하기

열 caterory 별 가중 평균

Out[183]:

	category	data	weights
0	а	-1.038668	0.194101
1	а	-0.652685	0.281413
2	а	-1.224352	0.786156
3	а	-0.154844	0.205984
4	b	-0.013619	0.068997
5	b	0.568799	0.217711
6	b	-1.351436	0.542650
7	b	-0.797593	0.974070

```
In [184]: grouped = df.groupby('category')
    get_wavg = lambda g: np.average(g['data'], weights=g['weights'])
    grouped.apply(get_wavg)
```

Out[184]: category a -0.940077

> b -0.769298 dtype: float64

미국 주식 종가 데이터 확인

- 메소드 read_csv(...)
 - 옵션 parse_dates=True
 - 날짜 정보를 해석하여 DataTime 유형으로 저장

```
!chcp 65001
In [12]:
         Active code page: 65001
In [15]: !type examples\stock px 2.csv
         ,AAPL,MSFT,XOM,SPX
         2003-01-02 00:00:00,7.4,21.11,29.22,909.03
         2003-01-03 00:00:00,7.45,21.14,29.24,908.59
         2003-01-06 00:00:00.7.45.21.52.29.96.929.01
         2003-01-07 00:00:00,7.43,21.93,28.95,922.93
         2003-01-08 00:00:00,7.28,21.31,28.83,909.93
         2003-01-09 00:00:00,7.34,21.93,29.44,927.57
         2003-01-10 00:00:00,7.36,21.97,29.03,927.57
         2003-01-13 00:00:00.7.32.22.16.28.91.926.26
         2003-01-14 00:00:00,7.3,22.39,29.17,931.66
         2003-01-15 00:00:00,7.22,22.11,28.77,918.22
         2003-01-16 00:00:00,7.31,21.75,28.9,914.6
         2003-01-17 00:00:00,7.05,20.22,28.6,901.78
         2003-01-21 00:00:00,7.01,20.17,27.94,887.62
         2003-01-22 00:00:00,6.94,20.04,27.58,878.36
         2003-01-23 00:00:00,7.09,20.54,27.52,887.34
         2003-01-24 00:00:00,6.9,19.59,26.93,861.4
         2003-01-27 00:00:00,7.07,19.32,26.21,847.48
         2003-01-28 00:00:00,7.29,19.18,26.9,858.54
         2002_01_20 00:00:00 7 47 10 61 27 88 864 26
```

```
In [8]: close px = pd.read csv('examples/stock px 2.csv', parse dates=True
                                 index col=0)
         close px.shape
Out[8]: (2214, 4)
In [4]: close_px = pd.read_csv('examples/stock_px_2.csv', index_col=0)
         close px.shape
Out[4]: (2214, 4)
 In [9]: close_px.info()
         <class 'pandas.core.frame.DataFrame'>
         DatetimeIndex: 2214 entries. 2003-01-02 to 2011-10-14
        Data columns (total 4 columns):
              Column Non-Null Count Dtype
              AAPL
                      2214 non-null
                                      float64
              MSFT
                      2214 non-null
                                      float64
              XOM
                      2214 non-null
                                      float64
              SPX
                      2214 non-null
                                      float64
         dtypes: float64(4)
         memory usage: 86.5 KB
In [10]:
         close px.index
Out [10]
         DatetimeIndex(i
                         '2003-01-02', '2003-01-03', '2003-01-06', '2003-01-07',
                         '2003-01-08'. '2003-01-09'. '2003-01-10'. '2003-01-13'.
                         '2003-01-14', '2003-01-15',
                         '2011-10-03', '2011-10-04', '2011-10-05', '2011-10-06',
                         '2011-10-07', '2011-10-10', '2011-10-11', '2011-10-12',
                         '2011-10-13', '2011-10-14'],
                       dtype='datetime64[ns]', length=2214, freq=None)
```

미국 주식 종가 데이터프레임 close_px

• 애플, 마소, 엑슨모빌, S&P 500 지수

In [16]:	close_px[-4:]						
Out[16]:		AAPL	MSFT	хом	SPX		
	2011-10-11	400.29	27.00	76.27	1195.54		
	2011-10-12	402.19	26.96	77.16	1207.25		
	2011-10-13	408.43	27.18	76.37	1203.66		
	2011-10-14	422.00	27.27	78.11	1224.58		

PYTHON PROGRAMMING

SPX와 주식과의 연관관계


- 일일 수익률(일일 변화율)로 상 관관계 분석
 - SPX와 다른 3 회사의 연관관계

- 애플과 마소의 상관관계

In [190]:	spx_corr = lambda x: x.corrwith(x['SPX'])
In [191]:	rets = close_px.pct_change().dropna()
In [192]:	get_year = lambda x: x.year
	by_year = rets.groupby(get_year)
	by_year.apply(spx_corr)
	and a second

Out[192]:

4	AAPL	MSFT	XOM	SPX
2003	0.541124	0.745174	0.661265	1.0
2004	0.374283	0.588531	0.557742	1.0
2005	0.467540	0.562374	0.631010	1.0
2006	0.428267	0.406126	0.518514	1.0
2007	0.508118	0.658770	0.786264	1.0
2008	0.681434	0.804626	0.828303	1.0
2009	0.707103	0.654902	0.797921	1.0
2010	0.710105	0.730118	0.839057	1.0
2011	0.691931	0.800996	0.859975	1.0



선형회귀

• 딥러닝에서 학습

https://datascienceschool.net/viewnotebook/58269d7f52bd49879965cdc472 1da42d/

계량경제 라이브러리 statsmodels

- statsmodels 패키지의 OLS 클래스
 - 선형 회귀분석
 - model = OLS(y, X)
 - fit 메서드로 모형 추정
 - result = model.fit()
 - 별도의 RegressionResults 클래스 객체로 출력
 - 메소드 fit()의 결과인 RegressionResults 클래스의 속성
 - Params: 가중치 벡터
 - resid: 잔차 벡터


10장 데이터 집계와 그룹 연산

피빗데이블라 교차일람표

2h

피벗 테이블 개요

- 데이터 요약화 도구
 - 하나 이상의 키로 수집해서, 키를 행과 열에 나눠 데이터를 저장, 기본 값은 평균 값
 - Groupby()에 의한 계층적 색인을 활용한 재형성 기능
- 판다스 모듈의 최상위 함수
 - 데이터프레임 panda.pivot_table()



PYTHON PROGRAMMING

팁 데이터

- In [201]: tips.pivot_table(index=['day', 'smoker'])
- Out[201]:
- 요일과 흡연자 기준 - 평균 구하기
- 메소드 pivot_table
- 메소드 groupby

		size	tip	tip_pct	total_bill
day	smoker				
Fri	No	2.250000	2.812500	0.151650	18.420000
	Yes	2.066667	2.714000	0.174783	16.813333
Sat	No	2.555556	3.102889	0.158048	19.661778
	Yes	2.476190	2.875476	0.147906	21.276667
Sun	No	2.929825	3.167895	0.160113	20.506667
	Yes	2.578947	3.516842	0.187250	24.120000
Thur	No	2.488889	2.673778	0.160298	17.113111
	Yes	2.352941	3.030000	0.163863	19.190588

In [204]: tips.groupby(['day', 'smoker']).mean()

Out[204]:

		total_bill	tip	size	tip_pct		
day	smoker						
Fri	No	18.420000	2.812500	2.250000	0.151650		
	Yes	16.813333	2.714000	2.066667	0.174783		
Sat	No	19.661778	3.102889	2.555556	0.158048		
	Yes	21.276667	2.875476	2.476190	0.147906		
Sun	No	20.506667	3.167895	2.929825	0.160113		
	Yes	24.120000	3.516842	2.578947	0.187250		
Thur	No	17.113111	2.673778	2.488889	0.160298		
	Yes	19.190588	3.030000	2.352941	0.163863		

Pivot_table 데이터, 인덱스, 열명 지정


• 목적

시간(time)과 요일(day)별로 그룹 수(size)와 팁 비율(tip_pct)을 흡연(smoker) 구분(No, Yes)에따라 평균 구하기

• 다양한 옵션

- 옵션 index
- 옵션 columns
- 옵션 margins=True
 - 행과 열에 all이 추가
 - 적절한 부분합 포 함되도록






time	day						
Dinner	Fri	2.000000	2.222222	2.166667	0.139622	0.165347	0.158916
	Sat	2.555556	2.476190	2.517241	0.158048	0.147906	0.153152
	Sun	2.929825	2.578947	2.842105	0.160113	0.187250	0.166897
	Thur	2.000000	NaN	2.000000	0.159744	NaN	0.159744
Lunch	Fri	3.000000	1.833333	2.000000	0.187735	0.188937	0.188765
	Thur	2.500000	2.352941	2.459016	0.160311	0.163863	0.161301
AII	The state of the s	2.668874	2.408602	2.569672	0.159328	0.163196	0.160803

평균이 아닌 다른 집계 함수를 지정

- 옵션 aggfunc=
 - aggfunc=len
 - 총 개수, 빈도



Sat Dinner

Thur Dinner

2 0.098204

2 0.159744

17.82 1.75

18.78 3.00

242

243

비어 있는 값 수정

• 옵션 fill_value=

In [221]: tips.pivot_table('tip_pct', index=['time', 'size', 'smoker'], columns='day', aggfunc='mean', fill_value=0)

Out[221]:

Out[222]:

		day	Fri	Sat	Sun	Thur
time	size	smoker				
Dinner	1	No	NaN	0.137931	NaN	NaN
		Yes	NaN	0.325733	NaN	NaN
2		No	0.139622	0.162705	0.168859	0.159744
		Yes	0.171297	0.148668	0.207893	NaN
	3	No	NaN	0.154661	0.152663	NaN
Lunch	3	Yes	NaN	NaN	NaN	0.204952
	4	No	NaN	NaN	NaN	0.138919
		Yes	NaN	NaN	NaN	0.155410
	5	No	NaN	NaN	NaN	0.121389
	6	No	NaN	NaN	NaN	0.173706

21 rows	× 4	co	lumns
---------	-----	----	-------

		day	Fri	Sat	Sun	Thur /
time	size	smoker				
Dinner	1	No	0.000000	0.137931	0.000000	0.000000
		Yes	0.000000	0.325733	0.000000	0.000000
	2	No	0.139622	0.162705	0.168859	0.159744
		Yes	0.171297	0.148668	0.207893	0.000000
	3	No	0.000000	0.154661	0.152663	0.000000
Lunch	3	Yes	0.000000	0.000000	0.000000	0.204952
	4	No	0.000000	0.000000	0.000000	0.138919
		Yes	0.000000	0.000000	0.000000	0.155410
	5	No	0.000000	0.000000	0.000000	0.121389
	6	No	0.000000	0.000000	0.000000	0.173706

21 rows × 4 columns

피벗 테이블 옵션

DataFrame.pivot_table(self, values=None, index=None, columns=None, aggfunc='mean', fill_value=None, margins=False, dropna=True, margins_name='All', observed=False)

Table 10-2. pivot_table options


Function name	Description			
values	Column name or names to aggregate; by default aggregates all numeric columns			
index	Column names or other group keys to group on the rows of the resulting pivot table			
columns	Column names or other group keys to group on the columns of the resulting pivot table			
aggfunc	Aggregation function or list of functions ('mean' by default); can be any function valid in a groupby context			
fill_value	Replace missing values in result table			
dropna	If True, do not include columns whose entries are all NA			
margins	Add row/column subtotals and grand total (False by default)			

pandas pivot table explained

V	7	i	A	i	0
V			n	ı	u

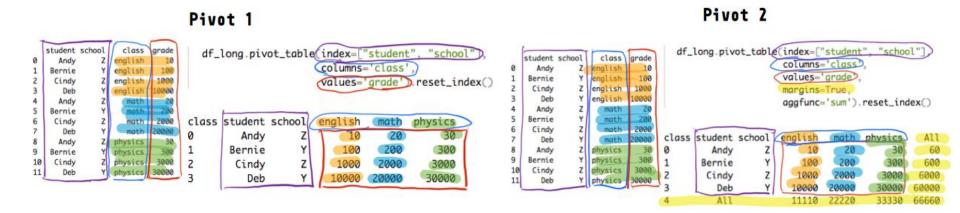
Pivot_table

	Account	Name	Rep	Manager	Product	Quantity	Price	Status
0	714466	Trantow-Barrows	Craig Booker	Debra Henley	CPU	1	30000	presented
1	714466	Trantow-Barrows	Craig Booker	Debra Henley	Software	1	10000	presented
2	714466	Trantow-Barrows	Craig Booker	Debra Henley	Maintenance	2	5000	pending
3	737550	Fritsch, Russel and Anderson	Craig Booker	Debra Henley	CPU	1	35000	declined
4	146832	Kiehn-Spinka	Daniel Hilton	Debra Henley	CPU	2	65000	won





Pivot_table 요약

Reshaping pandas dataframe with pivot_table (wide to long)










교차 일람표 개요

- pandas.crosstab(inde x, columns, values=None, rownames=None, colnames=None, aggfunc=None, margins=False, margins_name: str = 'All', dropna: bool = True, normalize=False)
- 그룹의 빈도를 계산하 기 위한 피벗테이블의 한 유형
 - crosstab의 처음 두 인자는 배열이나 시 리즌 혹은 배열의 리 스트
 - 행, 열 요인 기준 별로 빈도를 세어서 도수분포 표(frequency table), 교 차표(contingency table) 를 생성



PYTHON PROGRAMMING

교차 일람표

- 메소드 crosstab
 - 첫 인자: index
 - 두 번째 인자: columns
 - 그룹 빈도수를 계산
- 국가 별 손잡이 수

0 0	imple	Nationality	Handedness	
0	1			
	'	USA	Right-handed	
1	2	Japan	Left-handed	
2	3	USA	Right-handed	
3	4	Japan	Right-handed	
4	5	Japan	Left-handed	
5	6	Japan	Right-handed	
6	7	USA	Right-handed	
7	8	USA	Left-handed	
8	9	Japan	Right-handed	
9	10	USA	Right-handed	
				,

In [226]: data

Out [226] :

Handedness	Left-handed	Right-handed	All
Nationality)		
Japan	2	3	5
USA	1	4	5
All	3	7	10

In [232]: data.pivot_table('Sample', index='Nationality', columns='Handedness', aggfunc=len, margins=True)

Out [232] :

Handedness	Lett-nanded	Right-handed	AII
Nationality			
Japan	2	3	5
USA	1	4	5
All	3	7	10

o n

팁 데이터의 교차 일람표

- 시간과 요일에 따른 흡연 여부의 빈도 수
 - 다음 결과 동일
 - crosstab()
 - 메소드 pivot_table()
 - aggfunc=len

 In [249]:
 tips

 Out [249]:
 total_bill
 tip
 smoker
 day
 time
 size
 tip_pct

 0
 16.99
 1.01
 No
 Sun
 Dinner
 2
 0.059447

	total_bill	tip	smoker	day	time	size	tip_pct	
0	16.99	1.01	No	Sun	Dinner	2	0.059447	
1	10.34	1.66	No	Sun	Dinner	3	0.160542	
2	21.01	3.50	No	Sun	Dinner	3	0.166587	
3	23.68	3.31	No	Sun	Dinner	2	0.139780	
4	24.59	3.61	No	Sun	Dinner	4	0.146808	
239	29.03	5.92	No	Sat	Dinner	3	0.203927	
240	27.18	2.00	Yes	Sat	Dinner	2	0.073584	
241	22.67	2.00	Yes	Sat	Dinner	2	0.088222	
242	17.82	1.75	No	Sat	Dinner	2	0.098204	
243	18.78	3.00	No	Thur	Dinner	2	0.159744	
244 r	ows × 7 c	olumn	s					

In [228]: pd.crosstab([tips.time, tips.day], tips.smoker, margins=True)

	smoker	No	Yes	All
time	day			
Dinner	Fri	3	9	12
	Sat	45	42	87
	Sun	57	19	76
	Thur	1	0	1
Lunch	Fri	1	6	7
	Thur	44	17	61
All		151	93	244

Out [228]:

열 'smoker', 'day', 'time'은 제외하고 모두 가능

In [247]: tips.pivot_table('size', index=['time', 'day'], columns='smoker', aggfunc=len, margins=True, fill_value=0)

	smoker	No	Yes	AII
time	day			
Dinner	Fri	3	9	12
	Sat	45	42	87
	Sun	57	19	76
	Thur	1	0	1
Lunch	Fri	1	6	7
	Thur	44	17	61
All		151	93	244

Python