# 파이썬 라이브러리를 활용한 데이터 분석

14장 데이터 분석 예제

2020.07.09号 2h

# 14장 데이터 분석 예제

URL 총약 서비소 정보 분석

2h

# Bit.ly

- URL 축약 서비스 업체
- 파일 내용
  - 미국 정보 웹사이트 USA.gov와 제휴하여
    - .gov와 .mil을 축약한 사용자 들의 익명 정보 제공
  - 서비스를 사용한 정보를 행마다 저장한 파일

### • 파이참에서 확인 가능

# JSON(JavaScript Object Notation) 형식

### 특징

- JSON은 경량(Lightweight)의 DATA-교환 형식
- Javascript에서 객체를 만들 때 사용하는 표현식을 의미
- 사람과 기계 모두 이해하기 쉬우며 용량이 작음
  - 최근에는 JSON이 XML을 대체해서 데이터 전송 등에 많이 사용
- 특정 언어에 종속되지 않으며, 대부분의 프로그래밍 언어에서 JSON 포맷의 데이터 를 핸들링 할 수 있는 라이브러리를 제공

### • 파이썬의 사전 형식

```
{
   "firstName": "Kwon",
   "lastName": "YoungJae",
   "email": "kyoje11@gmail.com",
   "hobby": ["puzzles","swimming"]
}
```

### 파일 읽기

- 스냅 샷 파일의 행
  - JSON
  - \_ 한 줄 검사
- records 객체

  - 파이썬 사전 리스트

```
- 총 3560개 <sub>In [10]:</sub>
```

```
records = [ison.loads(line) for line in open(path, encoding="utf-8")]
records [0]
```

Out[5]: '{ "a": "Mozilla₩₩/5.0 (Windows NT 6.1; WOW64) AppleWebKit₩₩/535.11 (KHTML, like Ge

cko) Chrome##/17.0.963.78 Safari##/535.11", "c": "US", "nk": 1, "tz": "America##/Ne w\_York", "gr": "MA", "g": "A6qOVH", "h": "wfLQtf", "I": "orofrog", "aI": "en-US,en;

q=0.8", "hh": "1.usa.gov", "r": "http:##/##/www.facebook.com##/I##/7AQEFzjSi##/1.us 

331923247, "hc": 1331822918, "cy": "Danvers", "II": [ 42.576698, -70.954903 ] }\#n'

```
Out[10]: {'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko) C
          hrome/17.0.963.78 Safari/535.11'.
           'c': 'US',
           'tz': 'America/New_York',
           ʻarʻ: MA':
           'g': 'A6a0VH',
           'h': 'wfLQtf',
           'l': 'orofrog',
           'al': 'en-US,en;q=0.8'.
           'hh': '1.usa.gov',
           'r': 'http://www.facebook.com/I/7AQEFzjSi/1.usa.gov/wfLQtf',
           'u': 'http://www.ncbi.nlm.nih.gov/pubmed/22415991'.
           't': 1331923247.
           'hc': 1331822918,
           'cv': 'Danvers'.
           '11': [42.576698. -70.954903]}
```

path = 'datasets/bitly usagov/example.txt'

In [5]: import ison

open(path).readline()

### 표준 시간대 파악

- 표준 시간대
  - tz 필드
  - 모든 행이 키 'tz'가 있는 건 아님

In [15]: records[0]['tz']

• 오류 발생

```
Out[15]: 'America/New_York'
In [13]: time_zones = [rec['tz'] for rec in records]
         KevError
                                                    Traceback (most recent call last)
         <ipython-input-13-f3fbbc37f129> in <module>
          ----> 1 time zones = [rec['tz'] for rec in records]
         <ipython-input-13-f3fbbc37f129> in <listcomp>(.0)
          ----> 1 time_zones = [rec['tz'] for rec in records]
          KevError: 'tz'
In [25]: records [:10]
            'hh': '1.usa.gov'
            'r': 'http://www.facebook.com/l.php?u=http%3A%2F%2F1.usa.gov%2FzkpJBR&h=fAQG5ntSG
         AQHqKPIWzuJKUA9LYeckHZCUxvjQipJDd7Rmmw',
            'u': 'http://www.nasa.gov/mission_pages/nustar/main/index.html'.
            't': 1331923254.
            'hc': 1331922854}.
           {'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko)
         Chrome/17.0.963.79 Safari/535.11',
            'c': None,
            'nk': 0,
            'tz': ''
            'g': 'zCaLwp',
            'h': 'zUtu0u',
            'l': 'alelex88'.
            'al': 'pt-BR.pt;g=0.8.en-US;g=0.6.en;g=0.4'.
            'hh': '1.usa.gov'.
            'r': 'http://t.co/o1Pd0WeV'.
            'u': 'http://apod.nasa.gov/apod/ap120312.html'.
            't': 1331923255,
            'hc': 1331923068}1
```

# 파이썬으로 표준시간대 세기(1)

- 키 tz 없는 행 처리
  - 키가 있는 것만
    - time\_zones에 추가
  - 키 'tz'의 값으로
    - "도 많음
  - 총 3560개
    - 키 'tz'가 있는 것은
      - 3440 개

```
In [29]: time zones = [rec['tz'] for rec in records if 'tz' in rec]
         time zones[:10]
Out[29]: ['America/New_York',
          'America/Denver',
          'America/New York'
          'America/Sao_Paulo'
          'America/New York'.
          'America/New_York',
           'Europe/Warsaw',
In [30]: len(time zones)
                                    타임존이
Out [30]: 3440 _____
                                   있는 갯수
In [31]: | time_zones2 = [rec.get('tz', None) for rec in records]
         len(time_zones2)
                                   타임존이 없는
Out [31]: 3560
                                   None도 추가
```

### defaultdict와 counter

- 표준 패키지 collections
  - defaultdict
    - 딕셔너리(dictionary)와 거의 비슷하지만 키 값이 없을 경우 미리 지정해 놓은 초기(default) 값을 지정하는 dictionary
  - Counter
    - 컨테이너에 동일한 값의 자료 가 몇개인지를 파악하는데 사 용하는 객체
      - A Counter is a dict subclass for counting hashable objects.
    - collections.Counter()의 결과 값(return)은 딕셔너리 형태
    - 메소드 most\_common(n)
      - 빈도 수 내림차순으로

```
In [9]: from collections import defaultdict
         s = ['a', 'b', 'c', 'b', 'a', 'b', 'c']
         d = defaultdict(int)
         for k in s:
             d[k] += 1
         d
Out[9]: defaultdict(int, {'a': 2, 'b': 3, 'c': 2})
In [20]: c = Counter(s)
Out[20]: Counter({'a': 2, 'b': 3, 'c': 2})
In [13]: from collections import Counter
         Ist = ['aa', 'cc', 'dd', 'aa', 'bb', 'ee']
         print(Counter(Ist))
         Counter({'aa': 2, 'cc': 1, 'dd': 1, 'bb': 1, 'ee': 1})
In [17]: Counter({'가': 3, '나': 2, '다': 4})
Out[17]: Counter({'가': 3, '나': 2, '다': 4})
```

# 파이썬으로 표준시간대 세기(2)

### • 사전 counts에는 표준 시간대 수가 저장

```
In [32]: def get_counts(sequence):
                                                                     In [34]: counts['America/New_York']
            counts = {}
             for \times in sequence:
                                                                     Out [34]: 1251
                 if x in counts:
                    counts[x] += 1
                                                                              len(time_zones)
                                                                     In [35]:
                else:
                    counts[x] = 1
                                                                     Out [35]: 3440
             return counts
In [33]: from collections import defaultdict
                                                                              딕셔너리(dictionary)와 거의 비
                                                                              슷하지만 키 값이 없을 경우 미
         def get counts2(sequence):
                                                                              리 지정해 놓은 초기(default)
             counts = defaultdict(int) # values will initialize to 0
                                                                                값을 지정하는 dictionary
             for x in sequence:
                counts[x] += 1
             return counts
In [22]: counts = get_counts(time_zones)
         counts
Out [22]: {'America/New York': 1251.
          'America/Denver': 191,
          'America/Sao_Paulo': 33,
          'Europe/Warsaw': 16.
          '': 521.
          'America/Los_Angeles': 382,
          'Asia/Hong_Kong': 10,
          'Europe/Rome': 27,
                                                                                                    Python
```

# 파이썬으로 표준시간대 세기(3)

• 상위 10 개의 표준시간대

 표준 라이브러리 collections.Counter 사용

### PYTHON PROGRAMMING

In [45]:

import pandas as pd

frame.info()

frame = pd.DataFrame(records)

# 데이터프레임으로 보기

메소드 info()

In [48]: frame

Out [48]

- 데이터프레임의 요약 정보
  - 행 3560, 열 18 개

	а	С	nk	tz	gr	g	h	1	al	hh	
0	Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi			America/New_York			wfLQtf	orofrog	en- US,en;q=0.8	1.usa.gov	ht
1	GoogleMaps/RochesterNY	US	0.0	America/Denver	UT	mwszkS	mwszkS	bitly	NaN	j.mp	
2	Mozilla/4.0 (compatible; MSIE 8.0; Windows NT	US	1.0	America/New_York	DC	xxr3Qb	xxr3Qb	bitly	en-US	1.usa.gov	
3	Mozilla/5.0 (Macintosh; Intel Mac OS X 10_6_8)	BR	0.0	America/Sao_Paulo	27	zCaLwp	zUtuOu	alelex88	pt-br	1.usa.gov	
4	Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi	US	0.0	America/New_York	MA	9b6kNI	9b6kNI	bitly	en- US,en;q=0.8	bit.ly	
3555	Mozilla/4.0 (compatible; MSIE 9.0; Windows NT	US	1.0	America/New_York	NJ	e5SvKE	fqPSr9	tweetdeckapi	en	1.usa.gov	
3556	Mozilla/5.0 (Windows NT 5.1) AppleWebKit/535.1	US	0.0	America/Chicago	ОК	jQLtP4	jQLtP4	bitly	en- US,en;q=0.8	1.usa.gov	
3557	GoogleMaps/RochesterNY	US	0.0	America/Denver	UT	mwszkS	mwszkS	bitly	NaN	j.mp	
3558	GoogleProducer	US	0.0	America/Los_Angeles	CA	zjtI4X	zjtl4X	bitly	NaN	1.usa.gov	
3559	Mozilla/4.0 (compatible; MSIE 8.0; Windows NT	US	0.0	America/New_York	VA	qxKrTK	qxKrTK	bitly	en-US	1.usa.gov	

<class 'pandas.core.frame.DataFrame'> RangeIndex: 3560 entries, 0 to 3559 Data columns (total 18 columns): Column Non-Null Count Dtype 3440 non-null obliect 2919 non-null object 3440 non-null float64 3 3440 non-null object tz 2919 non-null object gr 3440 non-null object 3440 non-null object 3440 non-null object 3094 non-null object 9 3440 non-null object 10 3440 non-null obliect 3440 non-null object float64 3440 non-null 3440 non-null float64 2919 non-null 14 CV object 2919 non-null object heartbeat 120 non-null float64 93 non-null kw obliect dtypes: float64(4), object(14) memory usage: 500.8+ KB In [46]: frame['tz'][:10] Out [46]: 0 America/New York America/Denver America/New York America/Sao Paulo

America/New\_York
America/New\_York
----Europe/Warsaw-

Name: tz. dtvpe: object

8 9

### 판다스로 표준시간대 세기

- 간단히 처리
  - 필드 tz 아예 빠진 것은
    - Misssing으로 넣고
  - 필드 tz가 "인 것은
    - 시간대 이름을 unknown으로

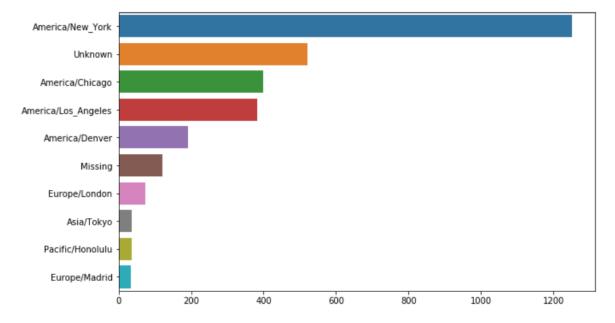
```
In [49]: tz counts = frame['tz'].value counts()
          tz counts[:10]
Out [49]: America/New York
                                 1251
                                  521
          America/Chicago
                                  400
         America/Los Angeles
                                  382
         America/Denver
                                  191
         Furope/London
                                   74
                                   37
         Asia/Tokvo
         Pacific/Honolulu
                                   36
         Furope/Madrid
                                   35
         America/Sao Paulo
         Name: tz. dtvpe: int64
In [54]: clean tz = frame['tz'].fillna('Missing')
         clean_tz[clean_tz == ''] = 'Unknown'
         tz_counts = clean_tz.value_counts()
         tz counts[:10]
Out [54]: America/New_York
                                 1251
         Unknown
                                  521
         America/Chicago
                                  400
         America/Los_Angeles
                                  382
         America/Denver
                                  191
         Missing
                                  120
         Europe/London
                                   74
                                   37
         Asia/Tokvo
         Pacific/Honolulu
                                   36
                                   35
         Europe/Madrid
         Name: tz. dtvpe: int64
```

# 수평 막대 그리기

### 가장 많이 나타난 시간대 10개

```
In [55]: plt.figure(figsize=(10, 4))
Out[55]: <Figure size 720x288 with 0 Axes>
         <Figure size 720x288 with 0 Axes>
In [56]:
         import seaborn as sns
         subset = tz_counts[:10]
         sns.barplot(y=subset.index, x=subset.values)
```

Out[56]: <matplotlib.axes.\_subplots.AxesSubplot at 0x2515b4c3f88>



### PYTHON PROGRAMMING

### 필드 a 분석

- URL 단축을 실행하는 정보
  - 브라우저
  - 단말기
  - 애플리케이션
- 브라우저의 종류와 수 알기
  - 첫 토큰(문자열)

```
In [57]: frame['a'][0:2]
Out [57]: n
              Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi...
                                          GoogleMaps/BochesterNY
         Name: a. dtvpe: object
In [58]: frame['a'][1]
Out [58]: 'GoogleMaps/RochesterNY'
In [59]: frame['a'][50]
Out [59]: 'Mozilla/5.0 (Windows NT 5.1; rv:10.0.2) Gecko/20100101 Firefox/10.0.2'
In [60]: frame['a'][51][:50] # long line
Out[60]: 'Mozilla/5.0 (Linux; U; Android 2.2.2; en-us; LG-P9'
In [61]: results = pd.Series([x.split()[0] for \times in frame.a.dropna()])
          results[:5]
Out [61]: 0
                          Mozilla/5.0
              GoogleMaps/RochesterNY
                          Mozilla/4.0
                          Mozilla/5.0
                          Mozilla/5.0
          dtype: object
In [63]: results.value_counts()[:8]
Out [63]: Mozilla/5.0
                                      2594
         Mozilla/4.0
                                       601
          GoogleMaps/RochesterNY
                                       121
          Opera/9.80
                                        34
          TEST INTERNET AGENT
                                        24
         GoogleProducer
                                        21
          Mozilla/6.0
         BlackBerry8520/5.0.0.681
                                         4
          dtype: int64
```

### PYTHON PROGRAMMING

# 시간대와 윈도 사용자

- 표준 시간대를
  - 윈도/비원도 사용자로 비교
    - 필드 a(agent 문자열)에 Windows 포함 여부에 따라

```
In [65]: cframe = frame[frame.a.notnull()]
In [66]: cframe = cframe.copy()
In [67]: cframe['os'] = np.where(cframe['a'].str.contains('Windows'),
                                  'Windows', 'Not Windows')
         cframe['os'][:5]
Out [67]: 0
                  Windows
              Not Windows
                  Windows
              Not Windows
                  Windows
         Name: os, dtype: object
In [68]: by tz os = cframe.groupby(['tz', 'os'])
In [69]: agg_counts = by_tz_os.size().unstack().fillna(0)
         agg counts[:10]
Out [69]:
```

Not Windows Windows

"으로 지정된 시간대의 수

tz		
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0
Africa/Lusaka	0.0	1.0
America/Anchorage	4.0	1.0
America/Argentina/Buenos_Aires	1.0	0.0
America/Argentina/Cordoba	0.0	1.0
America/Argentina/Mendoza	0.0	1.0

# 전체 표준시간대 순위

### • 먼저 표준시간대 합 구하고

- 순위의 arg 구하기
- 순위 첨자인 indexer로 자료를 take
  - 마지막 10개 가장 큰 값

Out[129]:

os I	Not	Windows	Windows
------	-----	---------	---------

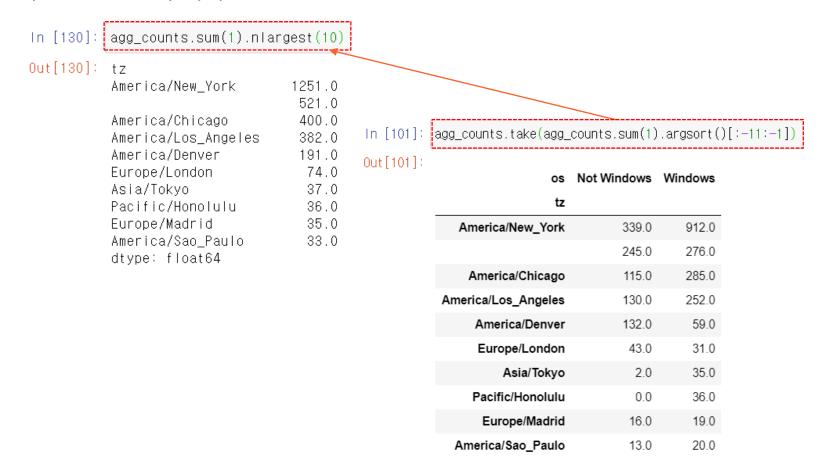
tz	[	
America/Sao_Paulo	13.0	20.0
Europe/Madrid	16.0	19.0
Pacific/Honolulu	0.0	36.0
Asia/Tokyo	2.0	35.0
Europe/London	43.0	31.0
America/Denver	132.0	59.0
America/Los_Angeles	130.0	252.0
America/Chicago	115.0	285.0
	245.0	276.0
America/New_York	339.0	912.0

In [91]:	agg_counts			KAMIMING
Out[91]:	os tz	Not Windows	Windows	
		245.0	276.0	
	Africa/Cairo	0.0	3.0	
	Africa/Casablanca	0.0	1.0	
	Africa/Ceuta	0.0	2.0	
	Africa/Johannesburg	0.0	1.0	
	Europe/Volgograd	0.0	1.0	
	Europe/Warsaw	1.0	15.0	
	Europe/Zurich	4.0	0.0	
	Pacific/Auckland	3.0	8.0	
	Pacific/Honolulu	0.0	36.0	
	97 rows × 2 columns			
In [72]:	# Use to sort in a indexer = agg_coun indexer[:10]			
Out[72]:	tz		24	
	Africa/Cairo Africa/Casablanca Africa/Ceuta Africa/Johannesbur Africa/Lusaka America/Anchorage America/Argentina/		20 21 92 87 53 54	시간대의 수 로 정렬한 첨 자를 준비, 가장 작은 10 개 출력
	America/Argentina/ America/Argentina/ dtype: int64	Cordoba	26 55	<b>y t h o n</b>

In [01]: and counts

### 전체 표준시간대 순위 간단히

- 판다스의 nlargest()
  - 다음으로 간단히 처리

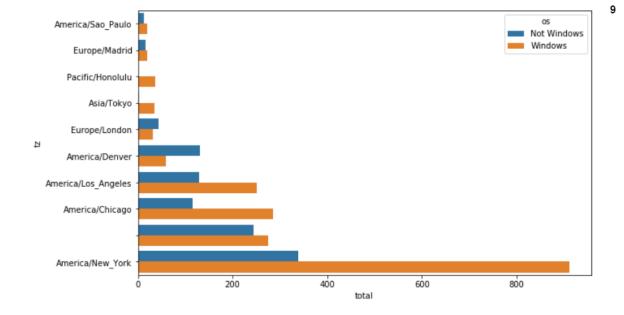


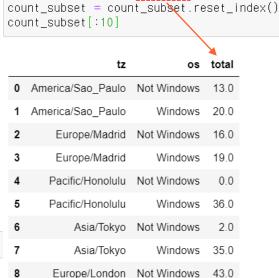


count\_subset = count\_subset.stack() In [103]: count\_subset count\_subset.name = 'total' Not Windows Windows Out[165]: America/Sao\_Paulo 13.0 20.0 19.0 Europe/Madrid 16.0 Pacific/Honolulu 0.0 36.0 Asia/Tokyo 2.0 35.0 Europe/London 43.0 31.0 America/Denver 132.0 59.0 America/Los\_Angeles 130.0 252.0 America/Chicago 285.0 115.0 245.0 276.0 America/New\_York 339.0 912.0

In [165]:

In [166]: sns.barplot(x='total', y='tz', hue='os', data=count\_subset) Out[166]: <matplotlib.axes.\_subplots.AxesSubplot at 0x25157a3bf08>





Windows

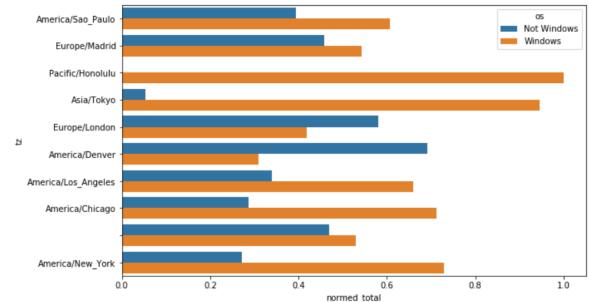
31.0

Europe/London

# Rearrange the data for plotting

### 시간대를 모두 정규화시킨 그래프

### • 시간대 사용자 총합을 1로 한 정규화된 그래프



### 정규화 계산 효율화

• 메소드 groupby와 transform 사용

```
In [89]: g = count_subset.groupby('tz')
  results2 = count_subset.total / g.total.transform('sum')
  results2
```

```
        tz
        os
        total

        0 America/Sao_Paulo
        Not Windows
        13.0

        1 America/Sao_Paulo
        Windows
        20.0

        2 Europe/Madrid
        Not Windows
        16.0
```

