파이썬 라이브러리를 활용한 데이터 분석

14장 데이터 분석 예제

2020.07.09목 2h

14장 데이터 분석 예제

URL 축약 서비스 정보 분석

2h

Bit.ly

- URL 축약 서비스 업체
- 파일 내용
  - 미국 정보 웹사이트 USA.gov와 제휴하여
    - **.gov와 .mil을 축약한 사용자 들의 익명 정보 제공**
  - 서비스를 사용한 정보를 행마다 저장한 파일
- 파이참에서 확인 가능

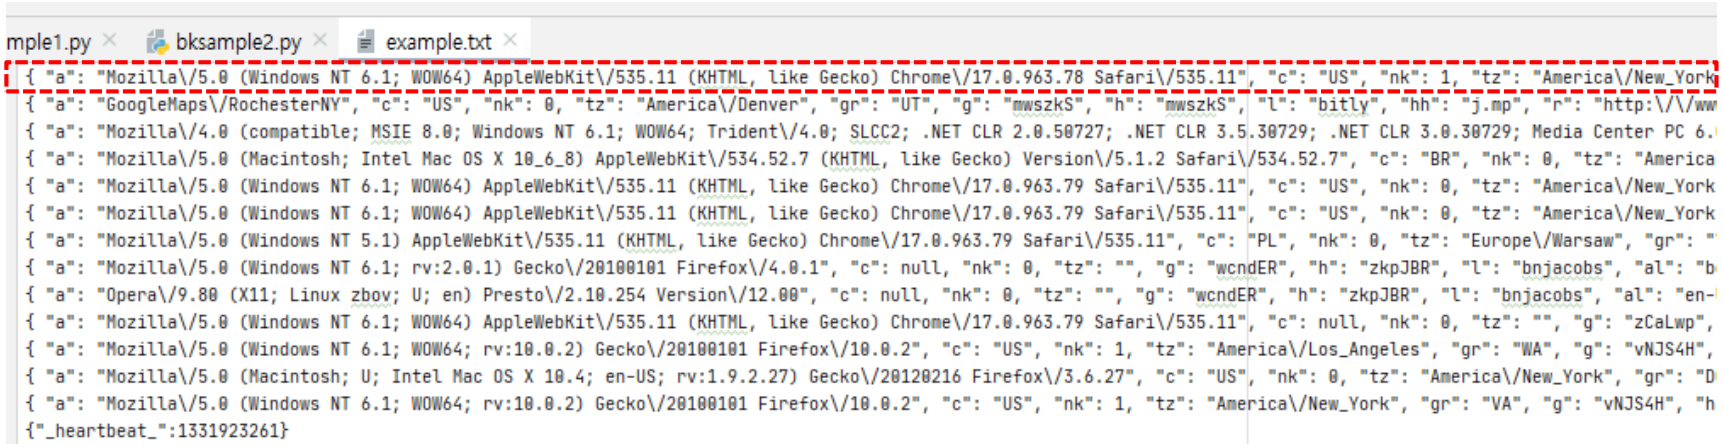

JSON(JavaScript Object Notation) 형식

- **특징**
  - JSON은 경량(Lightweight)의 DATA-교환 형식
  - Javascript에서 객체를 만들 때 사용하는 표현식을 의미
  - 사람과 기계 모두 이해하기 쉬우며 용량이 작음
    - **최근에는 JSON이 XML을 대체해서 데이터 전송 등에 많이 사용**
  - 특정 언어에 종속되지 않으며, 대부분의 프로그래밍 언어에서 JSON 포맷의 데이터를 핸들링 할 수 있는 라이브러리를 제공

- **파이썬의 사전 형식**

```
{
  "firstName": "Kwon",
  "lastName": "YoungJae",
  "email": "kyoje11@gmail.com",
  "hobby": ["puzzles","swimming"]
}
```

파일 읽기

- **스냅 샷 파일의 행**
  - JSON
  - 한 줄 검사
- **records 객체**
  - 파이썬 사전 리스트
  - 총 3560개

In [5]:
```
import json
path = 'datasets/bitly_usagov/example.txt'
open(path).readline()
```

Out[5]:
```
'{ "a": "Mozilla₩₩/5.0 (Windows NT 6.1; WOW64) AppleWebKit₩₩/535.11 (KHTML, like Ge
cko) Chrome₩₩/17.0.963.78 Safari₩₩/535.11", "c": "US", "nk": 1, "tz": "America₩₩/Ne
w_York", "gr": "MA", "g": "A6qOVH", "h": "wfLQtf", "l": "orofrog", "al": "en-US,en;
q=0.8", "hh": "1.usa.gov", "r": "http:₩₩/₩₩/www.facebook.com₩₩/l₩₩/7AQEFzjSi₩₩/1.us
a.gov₩₩/wfLQtf", "u": "http:₩₩/₩₩/www.ncbi.nlm.nih.gov₩₩/pubmed₩₩/22415991", "t": 1
331923247, "hc": 1331822918, "cy": "Danvers", "ll": [ 42.576698, -70.954903 ] }₩n'
```

In [10]:
```
records = [json.loads(line) for line in open(path, encoding="utf-8")]
records[0]
```

Out[10]:
```
{'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko) C
hrome/17.0.963.78 Safari/535.11',
 'c': 'US',
 'nk': 1,
 'tz': 'America/New_York',
 'gr': 'MA',
 'g': 'A6qOVH',
 'h': 'wfLQtf',
 'l': 'orofrog',
 'al': 'en-US,en;q=0.8',
 'hh': '1.usa.gov',
 'r': 'http://www.facebook.com/l/7AQEFzjSi/1.usa.gov/wfLQtf',
 'u': 'http://www.ncbi.nlm.nih.gov/pubmed/22415991',
 't': 1331923247,
 'hc': 1331822918,
 'cy': 'Danvers',
 'll': [42.576698, -70.954903]}
```

표준 시간대 파악

- **표준 시간대**
  - tz 필드
  - 모든 행이 키 'tz'가 있는 건 아님
    - **오류 발생**

```
In [15]: records[0]['tz']
Out[15]: 'America/New_York'

In [13]: time_zones = [rec['tz'] for rec in records]
---------------------------------------------------------------------------
KeyError                                  Traceback (most recent call last)
<ipython-input-13-f3fbbc37f129> in <module>
----> 1 time_zones = [rec['tz'] for rec in records]

<ipython-input-13-f3fbbc37f129> in <listcomp>(.0)
----> 1 time_zones = [rec['tz'] for rec in records]

KeyError: 'tz'

In [25]: records[:10]
  'hh': '1.usa.gov',
  'r': 'http://www.facebook.com/l.php?u=http%3A%2F%2F1.usa.gov%2FzkpJBR&h=fAQG5ntSG
AQHqKPIWzuJKUA9LYeckHZCUxvjQipJDd7Rmmw',
  'u': 'http://www.nasa.gov/mission_pages/nustar/main/index.html',
  't': 1331923254,
  'hc': 1331922854},
 {'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko)
Chrome/17.0.963.79 Safari/535.11',
  'c': None,
  'nk': 0,
  'tz': '',
  'g': 'zCaLwp',
  'h': 'zUtuOu',
  'l': 'alelex88',
  'al': 'pt-BR,pt;q=0.8,en-US;q=0.6,en;q=0.4',
  'hh': '1.usa.gov',
  'r': 'http://t.co/o1PdOWeV',
  'u': 'http://apod.nasa.gov/apod/ap120312.html',
  't': 1331923255,
  'hc': 1331923068}]
```

파이썬으로 표준시간대 세기(1)

- **키 tz 없는 행 처리**
  - 키가 있는 것만
    - **time_zones에 추가**
  - 키 'tz'의 값으로
    - **''도 많음**
  - 총 3560개
    - **키 'tz'가 있는 것은**
      - **3440 개**

```
In [29]: time_zones = [rec['tz'] for rec in records if 'tz' in rec]
         time_zones[:10]

Out[29]: ['America/New_York',
          'America/Denver',
          'America/New_York',
          'America/Sao_Paulo',
          'America/New_York',
          'America/New_York',
          'Europe/Warsaw',
          '',
          '',
          '']

In [30]: len(time_zones)

Out[30]: 3440

In [31]: time_zones2 = [rec.get('tz', None) for rec in records]
         len(time_zones2)

Out[31]: 3560
```

타임존이 있는 갯수

타임존이 없는 None도 추가

defaultdict와 counter

- **표준 패키지 collections**
  - defaultdict
    - **딕셔너리(dictionary)와 거의 비슷하지만 키 값이 없을 경우 미리 지정해 놓은 초기(default) 값을 지정하는 dictionary**
  - Counter
    - **컨테이너에 동일한 값의 자료가 몇개인지를 파악하는데 사용하는 객체**
      - **A Counter is a dict subclass for counting hashable objects.**
    - **collections.Counter()의 결과값(return)은 딕셔너리 형태**
    - **메소드 most_common(n)**
      - **빈도 수 내림차순으로**

```
In [9]:
from collections import defaultdict
s = ['a', 'b', 'c', 'b', 'a', 'b', 'c']
d = defaultdict(int)

for k in s:
    d[k] += 1
d

Out[9]: defaultdict(int, {'a': 2, 'b': 3, 'c': 2})
```

```
In [20]:
c = Counter(s)
c

Out[20]: Counter({'a': 2, 'b': 3, 'c': 2})
```

```
In [13]:
from collections import Counter
lst = ['aa', 'cc', 'dd', 'aa', 'bb', 'ee']
print(Counter(lst))

Counter({'aa': 2, 'cc': 1, 'dd': 1, 'bb': 1, 'ee': 1})
```

```
In [17]: Counter({'가': 3, '나': 2, '다': 4})

Out[17]: Counter({'가': 3, '나': 2, '다': 4})
```

파이썬으로 표준시간대 세기(2)

- **사전 counts에는 표준 시간대 수가 저장**

```
In [32]:
def get_counts(sequence):
    counts = {}
    for x in sequence:
        if x in counts:
            counts[x] += 1
        else:
            counts[x] = 1
    return counts
```

```
In [34]: counts['America/New_York']
Out[34]: 1251

In [35]: len(time_zones)
Out[35]: 3440
```

```
In [33]:
from collections import defaultdict

def get_counts2(sequence):
    counts = defaultdict(int) # values will initialize to 0
    for x in sequence:
        counts[x] += 1
    return counts
```

딕셔너리(dictionary)와 거의 비슷하지만 키 값이 없을 경우 미리 지정해 놓은 초기(default) 값을 지정하는 dictionary

```
In [22]:
counts = get_counts(time_zones)
counts
```

```
Out[22]: {'America/New_York': 1251,
 'America/Denver': 191,
 'America/Sao_Paulo': 33,
 'Europe/Warsaw': 16,
 '': 521,
 'America/Los_Angeles': 382,
 'Asia/Hong_Kong': 10,
 'Europe/Rome': 27,
```

파이썬으로 표준시간대 세기(3)

- 상위 10 개의 표준시간대

```
In [38]: def top_counts(count_dict, n=10):
             value_key_pairs = [(count, tz) for tz, count in count_dict.items()]
             value_key_pairs.sort()
             return value_key_pairs[-n:]
```

```
In [39]: top_counts(counts)
```

```
Out[39]: [(33, 'America/Sao_Paulo'),
          (35, 'Europe/Madrid'),
          (36, 'Pacific/Honolulu'),
          (37, 'Asia/Tokyo'),
          (74, 'Europe/London'),
          (191, 'America/Denver'),
          (382, 'America/Los_Angeles'),
          (400, 'America/Chicago'),
          (521, ''),
          (1251, 'America/New_York')]
```

- 표준 라이브러리 collections.Counter 사용

```
In [40]: from collections import Counter
         counts = Counter(time_zones)
         counts.most_common(10)
```

```
Out[40]: [('America/New_York', 1251),
          ('', 521),
          ('America/Chicago', 400),
          ('America/Los_Angeles', 382),
          ('America/Denver', 191),
          ('Europe/London', 74),
          ('Asia/Tokyo', 37),
          ('Pacific/Honolulu', 36),
          ('Europe/Madrid', 35),
          ('America/Sao_Paulo', 33)]
```

데이터프레임으로 보기

- **메소드 info()**
  - 데이터프레임의 요약 정보
    - **행 3560, 열 18 개**

In [45]:
```
import pandas as pd
frame = pd.DataFrame(records)
frame.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3560 entries, 0 to 3559
Data columns (total 18 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   a            3440 non-null   object
 1   c            2919 non-null   object
 2   nk           3440 non-null   float64
 3   tz           3440 non-null   object
 4   gr           2919 non-null   object
 5   g            3440 non-null   object
 6   h            3440 non-null   object
 7   l            3440 non-null   object
 8   al           3094 non-null   object
 9   hh           3440 non-null   object
 10  r            3440 non-null   object
 11  u            3440 non-null   object
 12  t            3440 non-null   float64
 13  hc           3440 non-null   float64
 14  cy           2919 non-null   object
 15  ll           2919 non-null   object
 16  _heartbeat_  120 non-null    float64
 17  kw           93 non-null     object
dtypes: float64(4), object(14)
memory usage: 500.8+ KB
```

In [48]:
```
frame
```

Out[48]:

	a	c	nk	tz	gr	g	h	l	al	hh	
0	Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi...	US	1.0	America/New_York	MA	A6qOVH	wfLQtf	orofrog	en-US,en;q=0.8	1.usa.gov	htt
1	GoogleMaps/RochesterNY	US	0.0	America/Denver	UT	mwszkS	mwszkS	bitly	NaN	j.mp	
2	Mozilla/4.0 (compatible; MSIE 8.0; Windows NT ...	US	1.0	America/New_York	DC	xxr3Qb	xxr3Qb	bitly	en-US	1.usa.gov	
3	Mozilla/5.0 (Macintosh; Intel Mac OS X 10_6_8)...	BR	0.0	America/Sao_Paulo	27	zCaLwp	zUtuOu	alelex88	pt-br	1.usa.gov	
4	Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi...	US	0.0	America/New_York	MA	9b6kNl	9b6kNl	bitly	en-US,en;q=0.8	bit.ly	
...	...	...	...	...	...	...	...	...	...	...	
3555	Mozilla/4.0 (compatible; MSIE 9.0; Windows NT ...	US	1.0	America/New_York	NJ	e5SvKE	fqPSr9	tweetdeckapi	en	1.usa.gov	
3556	Mozilla/5.0 (Windows NT 5.1) AppleWebKit/535.1...	US	0.0	America/Chicago	OK	jQLtP4	jQLtP4	bitly	en-US,en;q=0.8	1.usa.gov	
3557	GoogleMaps/RochesterNY	US	0.0	America/Denver	UT	mwszkS	mwszkS	bitly	NaN	j.mp	
3558	GoogleProducer	US	0.0	America/Los_Angeles	CA	zjtl4X	zjtl4X	bitly	NaN	1.usa.gov	
3559	Mozilla/4.0 (compatible; MSIE 8.0; Windows NT ...	US	0.0	America/New_York	VA	qxKrTK	qxKrTK	bitly	en-US	1.usa.gov	

3560 rows × 18 columns

In [46]:
```
frame['tz'][:10]
```

Out[46]:
```
0     America/New_York
1       America/Denver
2     America/New_York
3    America/Sao_Paulo
4     America/New_York
5     America/New_York
6       Europe/Warsaw
7
8
9
Name: tz, dtype: object
```

판다스로 표준시간대 세기

- **간단히 처리**
  - 필드 tz 아예 빠진 것은
    - **Missing으로 넣고**
  - 필드 tz가 ''인 것은
    - **시간대 이름을 unknown으로**

```
In [49]: tz_counts = frame['tz'].value_counts()
         tz_counts[:10]

Out[49]: America/New_York        1251
                                  521
         America/Chicago          400
         America/Los_Angeles      382
         America/Denver           191
         Europe/London             74
         Asia/Tokyo                37
         Pacific/Honolulu          36
         Europe/Madrid             35
         America/Sao_Paulo         33
         Name: tz, dtype: int64
```

```
In [54]: clean_tz = frame['tz'].fillna('Missing')
         clean_tz[clean_tz == ''] = 'Unknown'
         tz_counts = clean_tz.value_counts()
         tz_counts[:10]

Out[54]: America/New_York        1251
         Unknown                  521
         America/Chicago          400
         America/Los_Angeles      382
         America/Denver           191
         Missing                  120
         Europe/London             74
         Asia/Tokyo                37
         Pacific/Honolulu          36
         Europe/Madrid             35
         Name: tz, dtype: int64
```

수평 막대 그리기

- **가장 많이 나타난 시간대 10개**

```
In [55]: plt.figure(figsize=(10, 4))
Out[55]: <Figure size 720x288 with 0 Axes>

         <Figure size 720x288 with 0 Axes>

In [56]: import seaborn as sns
         subset = tz_counts[:10]
         sns.barplot(y=subset.index, x=subset.values)
Out[56]: <matplotlib.axes._subplots.AxesSubplot at 0x2515b4c3f88>
```

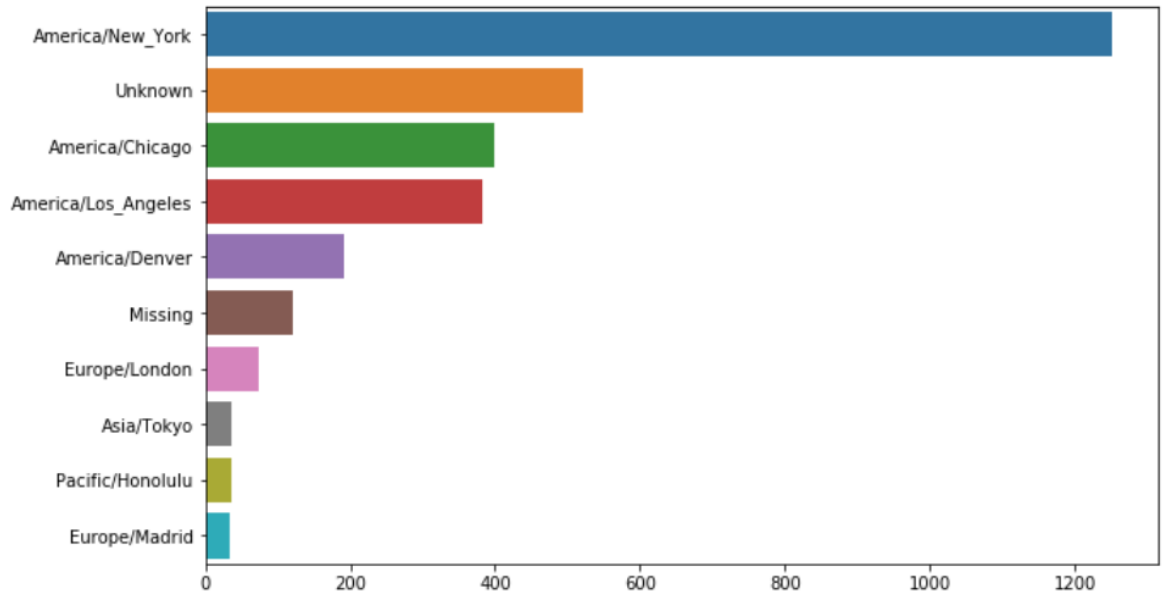

필드 a 분석

- URL 단축을 실행하는 정보
  - 브라우저
  - 단말기
  - 애플리케이션
- 브라우저의 종류와 수 알기
  - 첫 토큰(문자열)

```
In [57]: frame['a'][0:2]
Out[57]: 0    Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi...
         1                         GoogleMaps/RochesterNY
         Name: a, dtype: object

In [58]: frame['a'][1]
Out[58]: 'GoogleMaps/RochesterNY'

In [59]: frame['a'][50]
Out[59]: 'Mozilla/5.0 (Windows NT 5.1; rv:10.0.2) Gecko/20100101 Firefox/10.0.2'

In [60]: frame['a'][51][:50]  # long line
Out[60]: 'Mozilla/5.0 (Linux; U; Android 2.2.2; en-us; LG-P9'

In [61]: results = pd.Series([x.split()[0] for x in frame.a.dropna()])
         results[:5]
Out[61]: 0               Mozilla/5.0
         1    GoogleMaps/RochesterNY
         2               Mozilla/4.0
         3               Mozilla/5.0
         4               Mozilla/5.0
         dtype: object

In [63]: results.value_counts()[:8]
Out[63]: Mozilla/5.0                 2594
         Mozilla/4.0                  601
         GoogleMaps/RochesterNY       121
         Opera/9.80                    34
         TEST_INTERNET_AGENT           24
         GoogleProducer                21
         Mozilla/6.0                    5
         BlackBerry8520/5.0.0.681       4
         dtype: int64
```

시간대와 윈도 사용자

- **표준 시간대를**
  - 윈도/비원도 사용자로 비교
    - **필드 a(agent 문자열)에 Windows 포함 여부에 따라**

```
In [65]: cframe = frame[frame.a.notnull()]

In [66]: cframe = cframe.copy()

In [67]: cframe['os'] = np.where(cframe['a'].str.contains('Windows'),
                                 'Windows', 'Not Windows')
         cframe['os'][:5]

Out[67]: 0        Windows
         1    Not Windows
         2        Windows
         3    Not Windows
         4        Windows
         Name: os, dtype: object

In [68]: by_tz_os = cframe.groupby(['tz', 'os'])

In [69]: agg_counts = by_tz_os.size().unstack().fillna(0)
         agg_counts[:10]

Out[69]:
```

''으로 지정된 시간대의 수

os tz	Not Windows	Windows
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0
Africa/Lusaka	0.0	1.0
America/Anchorage	4.0	1.0
America/Argentina/Buenos_Aires	1.0	0.0
America/Argentina/Cordoba	0.0	1.0
America/Argentina/Mendoza	0.0	1.0

전체 표준시간대 순위

- **먼저 표준시간대 합 구하고**
  - 순위의 arg 구하기
  - 순위 첨자인 indexer로 자료를 take
    - **마지막 10개 가장 큰 값**

```
In [129]: count_subset = agg_counts.take(indexer[-10:])
          count_subset
```

Out[129]:

os / tz	Not Windows	Windows
America/Sao_Paulo	13.0	20.0
Europe/Madrid	16.0	19.0
Pacific/Honolulu	0.0	36.0
Asia/Tokyo	2.0	35.0
Europe/London	43.0	31.0
America/Denver	132.0	59.0
America/Los_Angeles	130.0	252.0
America/Chicago	115.0	285.0
	245.0	276.0
America/New_York	339.0	912.0

```
In [91]: agg_counts
```

Out[91]:

os / tz	Not Windows	Windows
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0
...	...	...
Europe/Volgograd	0.0	1.0
Europe/Warsaw	1.0	15.0
Europe/Zurich	4.0	0.0
Pacific/Auckland	3.0	8.0
Pacific/Honolulu	0.0	36.0

97 rows × 2 columns

```
In [72]: # Use to sort in ascending order
         indexer = agg_counts.sum(1).argsort()
         indexer[:10]
```

Out[72]:

```
tz
                                  24
Africa/Cairo                      20
Africa/Casablanca                 21
Africa/Ceuta                      92
Africa/Johannesburg               87
Africa/Lusaka                     53
America/Anchorage                 54
America/Argentina/Buenos_Aires    57
America/Argentina/Cordoba         26
America/Argentina/Mendoza         55
dtype: int64
```

시간대의 수로 정렬한 첨자를 준비, 가장 작은 10개 출력

전체 표준시간대 순위 간단히

- **판다스의 nlargest()**
  - 다음으로 간단히 처리

```
In [130]: agg_counts.sum(1).nlargest(10)

Out[130]: tz
          America/New_York       1251.0
                                  521.0
          America/Chicago         400.0
          America/Los_Angeles     382.0
          America/Denver          191.0
          Europe/London            74.0
          Asia/Tokyo               37.0
          Pacific/Honolulu         36.0
          Europe/Madrid            35.0
          America/Sao_Paulo        33.0
          dtype: float64
```

```
In [101]: agg_counts.take(agg_counts.sum(1).argsort()[:-11:-1])

Out[101]:
```

os / tz	Not Windows	Windows
America/New_York	339.0	912.0
	245.0	276.0
America/Chicago	115.0	285.0
America/Los_Angeles	130.0	252.0
America/Denver	132.0	59.0
Europe/London	43.0	31.0
Asia/Tokyo	2.0	35.0
Pacific/Honolulu	0.0	36.0
Europe/Madrid	16.0	19.0
America/Sao_Paulo	13.0	20.0

중첩 막대 그래프

In [103]:
```
count_subset
```

Out[103]:

tz	os	Not Windows	Windows
America/Sao_Paulo		13.0	20.0
Europe/Madrid		16.0	19.0
Pacific/Honolulu		0.0	36.0
Asia/Tokyo		2.0	35.0
Europe/London		43.0	31.0
America/Denver		132.0	59.0
America/Los_Angeles		130.0	252.0
America/Chicago		115.0	285.0
		245.0	276.0
America/New_York		339.0	912.0

In [165]:
```
# Rearrange the data for plotting
count_subset = count_subset.stack()
count_subset.name = 'total'
count_subset = count_subset.reset_index()
count_subset[:10]
```

Out[165]:

	tz	os	total
0	America/Sao_Paulo	Not Windows	13.0
1	America/Sao_Paulo	Windows	20.0
2	Europe/Madrid	Not Windows	16.0
3	Europe/Madrid	Windows	19.0
4	Pacific/Honolulu	Not Windows	0.0
5	Pacific/Honolulu	Windows	36.0
6	Asia/Tokyo	Not Windows	2.0
7	Asia/Tokyo	Windows	35.0
8	Europe/London	Not Windows	43.0
9	Europe/London	Windows	31.0

In [166]:
```
sns.barplot(x='total', y='tz', hue='os',  data=count_subset)
```

Out[166]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x25157a3bf08>
```

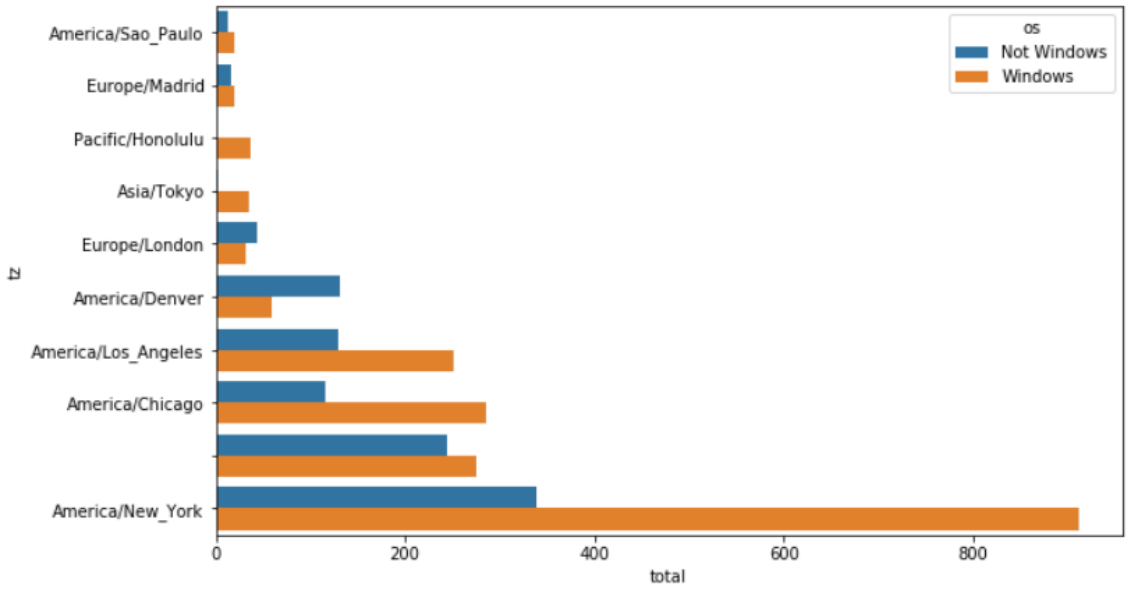

시간대를 모두 정규화시킨 그래프

- **시간대 사용자 총합을 1로 한 정규화된 그래프**

```
In [77]: def norm_total(group):
             group['normed_total'] = group.total / group.total.sum()
             return group

         results = count_subset.groupby('tz').apply(norm_total)

In [78]: plt.figure()
Out[78]: <Figure size 720x432 with 0 Axes>

         <Figure size 720x432 with 0 Axes>

In [79]: sns.barplot(x='normed_total', y='tz', hue='os',  data=results)
Out[79]: <matplotlib.axes._subplots.AxesSubplot at 0x2515b9366c8>
```

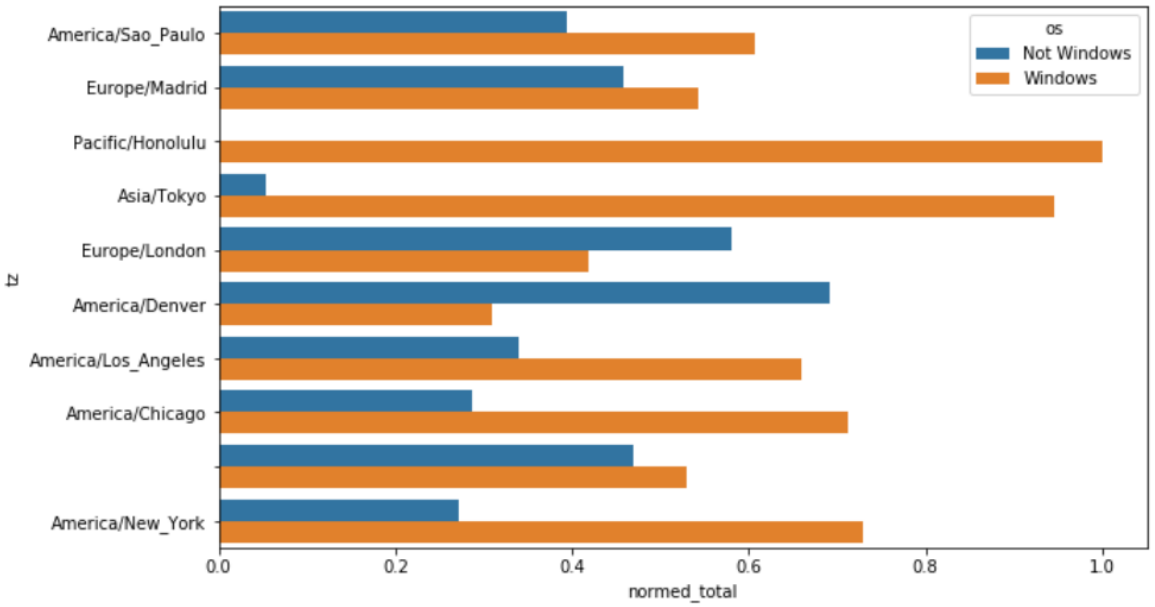

정규화 계산 효율화

- 메소드 groupby와 transform 사용

```
In [124]: count_subset
```

Out[124]:

	tz	os	total
0	America/Sao_Paulo	Not Windows	13.0
1	America/Sao_Paulo	Windows	20.0
2	Europe/Madrid	Not Windows	16.0

```
In [89]: g = count_subset.groupby('tz')
         results2 = count_subset.total / g.total.transform('sum')
         results2
```

```
Out[89]: 0     0.393939
         1     0.606061
         2     0.457143
         3     0.542857
         4     0.000000
         5     1.000000
         6     0.054054
         7     0.945946
         8     0.581081
         9     0.418919
         10    0.691099
         11    0.308901
         12    0.340314
         13    0.659686
         14    0.287500
         15    0.712500
         16    0.470250
         17    0.529750
         18    0.270983
         19    0.729017
         Name: total, dtype: float64
```

```
In [90]: sns.barplot(x=results2, y='tz', hue='os',  data=results)
```

```
Out[90]: <matplotlib.axes._subplots.AxesSubplot at 0x2515bbb1308>
```

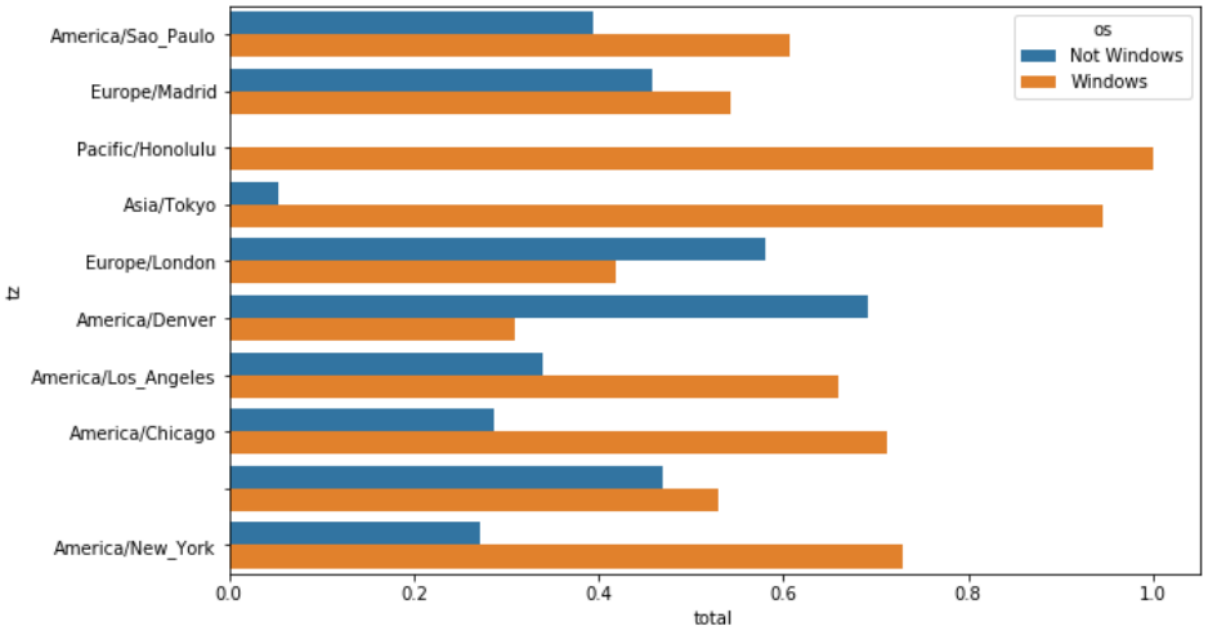

메소드 transform()

- 그룹별 대표 값을 만드는 것이 아니라 그룹별 계산을 통해 데이터프레임 자체를 변화
- 만들어진 데이터프레임의 크기는 원래 데이터프레임과 같음

```
In [132]: df = pd.DataFrame({'Year': [1997, 1997, 1997, 1998, 1999],
                             'Japan': [100, 100, 300, 200, 100],
                             'USA': [200, 100, 300, 400, 500],
                             'Canada': [400, 300, 200, 100, 400]},
                            index=['1', '2', '3', '4', '5'])
          df
```

Out[132]:

	Year	Japan	USA	Canada
1	1997	100	200	400
2	1997	100	100	300
3	1997	300	300	200
4	1998	200	400	100
5	1999	100	500	400

```
In [131]: df.groupby('Year').transform(np.sum)
```

Out[131]:

	Japan	USA	Canada
1	500	600	900
2	500	600	900
3	500	600	900
4	200	400	100
5	100	500	400

```
In [133]: df.groupby('Year').sum()
```

Out[133]:

Year	Japan	USA	Canada
1997	500	600	900
1998	200	400	100
1999	100	500	400