파이썬 라이브러리를 활용한 데이터 분석

14장 데이터 분석 예제

2020.07.09号 2h

14장 데이터 분석 예제

URL 총약 서비소 정보 분석

2h

Bit.ly

- URL 축약 서비스 업체
- 파일 내용
 - 미국 정보 웹사이트 USA.gov와 제휴하여
 - .gov와 .mil을 축약한 사용자 들의 익명 정보 제공
 - 서비스를 사용한 정보를 행마다 저장한 파일

• 파이참에서 확인 가능

JSON(JavaScript Object Notation) 형식

• 특징

- JSON은 경량(Lightweight)의 DATA-교환 형식
- Javascript에서 객체를 만들 때 사용하는 표현식을 의미
- 사람과 기계 모두 이해하기 쉬우며 용량이 작음
 - 최근에는 JSON이 XML을 대체해서 데이터 전송 등에 많이 사용
- 특정 언어에 종속되지 않으며, 대부분의 프로그래밍 언어에서 JSON 포맷의 데이터 를 핸들링 할 수 있는 라이브러리를 제공

• 파이썬의 사전 형식

```
{
   "firstName": "Kwon",
   "lastName": "YoungJae",
   "email": "kyoje11@gmail.com",
   "hobby": ["puzzles","swimming"]
}
```

파일 읽기

- 스냅 샷 파일의 행
 - JSON
 - 한 줄 검사
- records 객체
 - 파이썬 사전 리스트

```
In [5]: import json
path = 'datasets/bitly_usagov/example.txt'
open(path).readline()
```

```
In [10]: records = [ison.loads(line) for line in open(path, encoding="utf-8")]
         records [0]
Out[10]: {'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko) C
         hrome/17.0.963.78 Safari/535.11'.
           'c': 'US',
           'tz': 'America/New_York',
           ʻarʻ: MA':
           'g': 'A6a0VH',
           'h': 'wfLQtf',
           'l': 'orofrog'.
           'al': 'en-US,en;q=0.8'.
           'hh': '1.usa.gov',
           'r': 'http://www.facebook.com/I/7AQEFzjSi/1.usa.gov/wfLQtf',
           'u': 'http://www.ncbi.nlm.nih.gov/pubmed/22415991'.
           't': 1331923247.
           'hc': 1331822918.
           'cv': 'Danvers'.
           '11': [42.576698. -70.954903]}
```

표준 시간대 파악

• 표준시간대: tz 필드

In [15]: records[0]['tz']

- 모든 행이 tz 필드가 있는 건 아님
 - 오류 발생

```
Out[15]: 'America/New_York'
In [13]: time zones = [rec['tz'] for rec in records]
         KevError
                                                     Traceback (most recent call last)
          <ipython-input-13-f3fbbc37f129> in <module>
          ----> 1 time zones = [rec['tz'] for rec in records]
          <ipython-input-13-f3fbbc37f129> in <listcomp>(.0)
          ----> 1 time zones = [rec['tz'] for rec in records]
          KevError: 'tz'
In [25]: records [:10]
            'hh': '1.usa.gov'
            'r': 'http://www.facebook.com/l.php?u=http%3A%2F%2F1.usa.gov%2FzkpJBR&h=fAQG5ntSG
          AQHqKPIWzuJKUA9LYeckHZCUxvjQipJDd7Rmmw',
            'u': 'http://www.nasa.gov/mission_pages/nustar/main/index.html'.
            't': 1331923254.
            'hc': 1331922854}.
           {'a': 'Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/535.11 (KHTML, like Gecko)
         Chrome/17.0.963.79 Safari/535.11',
            'c': None,
            'nk': 0,
            'tz': ''
            'g': 'zCaLwp',
            'h': 'zUtu0u',
            'l': 'alelex88'.
            'al': 'pt-BR.pt;g=0.8.en-US;g=0.6.en;g=0.4'.
            'hh': '1.usa.gov'.
            'r': 'http://t.co/o1Pd0WeV'.
            'u': 'http://apod.nasa.gov/apod/ap120312.html'.
            't': 1331923255,
            'hc': 1331923068}1
```

파이썬으로 표준시간대 세기(1)

• 필드 tz 없는 행 처리

```
time_zones = [rec['tz'] for rec in records if 'tz' in rec]
         time zones[:10]
Out[29]: ['America/New_York',
          'America/Denver',
          'America/New York'
          'America/Sao_Paulo'
          'America/New_York',
          'America/New_York',
          'Europe/Warsaw',
In [30]:
        len(time_zones)
                                    타임존이
Out [30]: 3440 _____
                                   있는 갯수
In [31]: time_zones2 = [rec.get('tz', None) for rec in records]
         len(time_zones2)
                                   타임존이 없는
Out [31]: 3560 _____
                                   None도 추가
```

파이썬으로 표준시간대 세기(2)

• 사전 counts에는 표준 시간대 수가 저장

```
In [32]: def get_counts(sequence):
             counts = {}
             for \times in sequence:
                  if x in counts:
                     counts[x] += 1
                 else:
                     counts[x] = 1
             return counts
In [33]: from collections import defaultdict
         def get counts2(sequence):
             counts = defaultdict(int) # values will initialize to 0
             for x in sequence:
                 counts[x] += 1
             return counts
In [22]: counts = get_counts(time_zones)
         counts
Out [22]: {'America/New York': 1251.
           'America/Denver': 191,
           'America/Sao_Paulo': 33,
           'Europe/Warsaw': 16.
           '': 521.
           'America/Los_Angeles': 382,
           'Asia/Hong_Kong': 10,
           'Europe/Rome': 27,
```

```
In [34]: counts['America/New_York']
Out[34]: 1251
In [35]: len(time_zones)
Out[35]: 3440
```

파이썬으로 표준시간대 세기(3)

• 상위 10 개의 표준시간대

```
In [38]: def top_counts(count_dict, n=10):
             value key pairs = [(count, tz) for tz, count in count dict.items()]
             value kev pairs.sort()
              return value kev pairs[-n:]
In [39]: top counts(counts)
Out[39]: [(33, 'America/Sao_Paulo'),
           (35, 'Europe/Madrid'),
           (36, 'Pacific/Honolulu').
           (37, 'Asia/Tokyo'),
           (74, 'Europe/London'),
           (191, 'America/Denver').
           (382, 'America/Los_Angeles'),
           (400, 'America/Chicago'),
           (521, ''),
           (1251. 'America/New York')]
In [40]: from collections import Counter
          counts = Counter(time_zones)
          counts.most_common(10)
Out[40]: [('America/New_York', 1251),
           ('', 521),
           ('America/Chicago', 400),
           ('America/Los_Angeles', 382),
           ('America/Denver', 191),
           ('Europe/London', 74),
           ('Asia/Tokyo', 37),
           ('Pacific/Honolulu', 36),
           ('Europe/Madrid', 35),
```

('America/Sao Paulo', 33)]

 표준 라이브러리 collections.Counter 사용

PYTHON PROGRAMMING

Dtype

object

object

float64

obliect

obiect

object

object

object

object

object

object

object

float64

float64

object

object

object

float64

데이터프레임으로 보기

메소드 info()

In [48]

Out [48]

frame

- 데이터프레임의 요약 정보
 - 행 3560, 열 18 개

c nk h Mozilla/5.0 (Windows NT 6.1; WOW64) US 1.0 America/New_York MA A6qOVH wfLQtf 1.usa.gov htt US.en;q=0.8 AppleWebKi. 1 GoogleMaps/RochesterNY US 0.0 America/Denver UT mwszkS mwszkS bitly NaN Mozilla/4.0 (compatible; US 1.0 America/New York DC xxr3Qb xxr3Qb bitly en-US 1.usa.gov MSIF 8.0: Windows NT Mozilla/5.0 (Macintosh; BR 0.0 America/Sao Paulo 27 zCaLwp zUtuOu alelex88 1.usa.gov Intel Mac OS X 10 6 8).. Mozilla/5.0 (Windows NT 6.1; WOW64) US 0.0 America/New York MA 9b6kNI bit.ly US,en;q=0.8 AppleWebKi. Mozilla/4.0 (compatible; US 1.0 America/New York NJ e5SvKE fgPSr9 tweetdeckapi en 1.usa.gov MSIE 9.0; Windows NT .. Mozilla/5.0 (Windows NT US 0.0 America/Chicago OK iQLtP4 1.usa.gov 5.1) AppleWebKit/535.1... US,en;q=0.8 3557 GoogleMaps/RochesterNY US 0.0 America/Denver UT mwszkS mwszkS bitly NaN i.mp 3558 GoogleProducer US 0.0 America/Los Angeles CA zitl4X bitly NaN 1 usa gov Mozilla/4.0 (compatible; US 0.0 America/New York VA qxKrTK qxKrTK bitly en-US 1.usa.gov MSIE 8.0: Windows NT .. 3560 rows × 18 columns

<class 'pandas.core.frame.DataFrame'> RangeIndex: 3560 entries, 0 to 3559 Data columns (total 18 columns): Column Non-Null Count 3440 non-null 2919 non-null 3440 non-null 3 3440 non-null tz 2919 non-null gr 3440 non-null g 3440 non-null 3440 non-null 3094 non-null al 9 3440 non-null 10 3440 non-null 3440 non-null 3440 non-null 13 3440 non-null 14 2919 non-null CV 2919 non-null 16 heartbeat 120 non-null kw 93 non-null dtypes: float64(4), object(14) memory usage: 500.8+ KB frame['tz'][:10] America/New York America/Denver America/New York America/Sao Paulo America/New York

America/New York

Name: tz. dtvpe: object

.Furone/Warsaw.

import pandas as pd

frame.info()

frame = pd.DataFrame(records)

In [45]:

In [46]:

Out [46] :

8

9

판다스로 표준시간대 세기

- 간단히 처리
 - 필드 tz 아예 빠진 것은
 - Misssing으로 넣고
 - 필드 tz가 "인 것은
 - 시간대 이름을 unknown으로

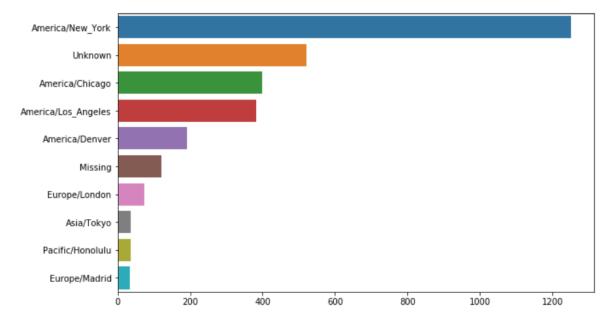
```
In [49]: tz counts = frame['tz'].value counts()
          tz counts[:10]
Out [49]: America/New York
                                 1251
                                  521
          America/Chicago
                                  400
         America/Los Angeles
                                  382
         America/Denver
                                  191
         Furope/London
                                   74
                                   37
         Asia/Tokvo
         Pacific/Honolulu
                                   36
         Furope/Madrid
                                   35
         America/Sao Paulo
         Name: tz. dtvpe: int64
In [54]: clean tz = frame['tz'].fillna('Missing')
         clean_tz[clean_tz == ''] = 'Unknown'
         tz_counts = clean_tz.value_counts()
         tz counts[:10]
Out [54]: America/New_York
                                 1251
         Unknown
                                  521
         America/Chicago
                                  400
         America/Los_Angeles
                                  382
         America/Denver
                                  191
         Missing
                                  120
         Europe/London
                                   74
                                   37
         Asia/Tokvo
         Pacific/Honolulu
                                   36
                                   35
         Europe/Madrid
         Name: tz. dtvpe: int64
```

수평 막대 그리기

가장 많이 나타난 시간대 10개

```
In [55]: plt.figure(figsize=(10, 4))
Out [55]: <Figure size 720x288 with 0 Axes>
         <Figure size 720x288 with 0 Axes>
In [56]:
         import seaborn as sns
         subset = tz_counts[:10]
         sns.barplot(y=subset.index, x=subset.values)
```

Out [56]: <matplotlib.axes._subplots.AxesSubplot at 0x2515b4c3f88>



PYTHON PROGRAMMING

필드 a 분석

- URL 단축을 실행하는 정보
 - 브라우저
 - 단말기
 - 애플리케이션
- 브라우저의 종류와 수 알기
 - 첫 토큰(문자열)

```
In [57]: frame['a'][0:2]
Out [57]: n
              Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKi...
                                          GoogleMaps/BochesterNY
         Name: a. dtvpe: object
In [58]: frame['a'][1]
Out [58]: 'GoogleMaps/RochesterNY'
In [59]: frame['a'][50]
Out [59]: 'Mozilla/5.0 (Windows NT 5.1; rv:10.0.2) Gecko/20100101 Firefox/10.0.2'
In [60]: frame['a'][51][:50] # long line
Out[60]: 'Mozilla/5.0 (Linux; U; Android 2.2.2; en-us; LG-P9'
In [61]: results = pd.Series([x.split()[0] for \times in frame.a.dropna()])
          results[:5]
Out [61]: 0
                          Mozilla/5.0
              GoogleMaps/RochesterNY
                          Mozilla/4.0
                          Mozilla/5.0
                          Mozilla/5.0
          dtype: object
In [63]: results.value_counts()[:8]
Out [63]: Mozilla/5.0
                                      2594
         Mozilla/4.0
                                       601
          GoogleMaps/RochesterNY
                                       121
          Opera/9.80
                                        34
          TEST INTERNET AGENT
                                        24
         GoogleProducer
                                        21
          Mozilla/6.0
         BlackBerry8520/5.0.0.681
                                         4
          dtype: int64
```

PYTHON PROGRAMMING

시간대와 윈도 사용자

- 표준 시간대를
 - 윈도/비원도 사용자로 비교
 - 필드 a(agent 문자열)에 Windows 포함 여부에 따라

os Not Windows Windows

Out [69]:

tz		
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0
Africa/Lusaka	0.0	1.0
America/Anchorage	4.0	1.0
America/Argentina/Buenos_Aires	1.0	0.0
America/Argentina/Cordoba	0.0	1.0
America/Argentina/Mendoza	0.0	1.0

전체 표준시간대 순위

• 먼저 표준시간대 합 구하고

- 순위의 arg 구하기

In [129]: count_subset = agg_counts.take(indexer[-10:])
count_subset

Out[129]:

os	Not Windows	Windows
tz		
America/Sao_Paulo	13.0	20.0
Europe/Madrid	16.0	19.0
Pacific/Honolulu	0.0	36.0
Asia/Tokyo	2.0	35.0
Europe/London	43.0	31.0
America/Denver	132.0	59.0
America/Los_Angeles	130.0	252.0
America/Chicago	115.0	285.0
	245.0	276.0
America/New_York	339.0	912.0

In [91]:	agg_counts	RAMMING

os Not Windows Windows

Out[91]:

tz		
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0
Europe/Volgograd	0.0	1.0
Europe/Warsaw	1.0	15.0
Europe/Zurich	4.0	0.0
Pacific/Auckland	3.0	8.0
Pacific/Honolulu	0.0	36.0

97 rows × 2 columns

In [72]: # Use to sort in ascending order
indexer = agg_counts.sum(1).argsort()
indexer[:10]

Out[72]: tz

	24
Africa/Cairo	20
Africa/Casablanca	21
Africa/Ceuta	92
Africa/Johannesburg	87
Africa/Lusaka	53
America/Anchorage	54
America/Argentina/Buenos_Aires	57
America/Argentina/Cordoba	26
America/Argentina/Mendoza	55
dtype: int64	

ython

전체 표준시간대 순위 간단히

판다스의 nlargest()

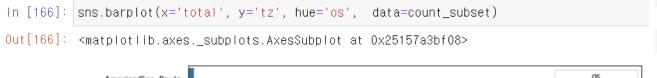
```
In [130]: agg_counts.sum(1).nlargest(10)
Out[130]: tz
          America/New_York
                                  1251.0
                                   521.0
                                   400.0
          America/Chicago
          America/Los_Angeles
                                   382.0
          America/Denver
                                   191.0
          Europe/London
                                    74.0
          Asia/Tokyo
                                    37.0
          Pacific/Honolulu
                                    36.0
                                    35.0
          Europe/Madrid
          America/Sao_Paulo
                                    33.0
          dtype: float64
```

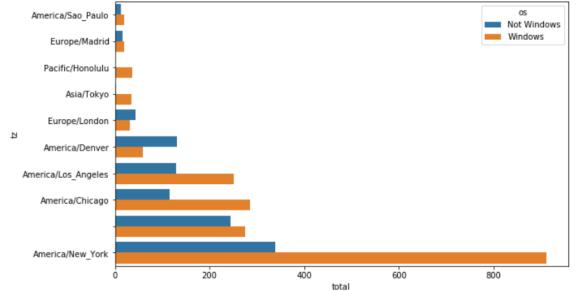
중첩 막대 그래프

In [165]: # Rearrange the data for plotting
 count_subset = count_subset.stack()
 count_subset.name = 'total'
 count_subset = count_subset.reset_index()
 count_subset[:10]

Out[165]:

	tz	os	total
0	America/Sao_Paulo	Not Windows	13.0
1	America/Sao_Paulo	Windows	20.0
2	Europe/Madrid	Not Windows	16.0
3	Europe/Madrid	Windows	19.0
4	Pacific/Honolulu	Not Windows	0.0
5	Pacific/Honolulu	Windows	36.0
6	Asia/Tokyo	Not Windows	2.0
7	Asia/Tokyo	Windows	35.0
8	Europe/London	Not Windows	43.0
9	Europe/London	Windows	31.0





시간대를 모두 정규화시킨 그래프

• 시간대 사용자 총합을 1로 한 정규화된 그래프

```
In [77]: def norm_total(group):
        group['normed_total'] = group.total / group.total.sum()
        return group

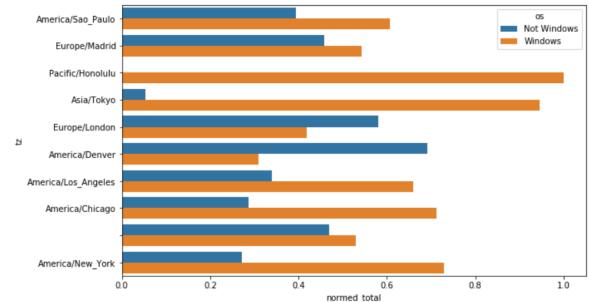
        results = count_subset.groupby('tz').apply(norm_total)

In [78]: plt.figure()

Out[78]: <Figure size 720x432 with 0 Axes>
        <Figure size 720x432 with 0 Axes>

In [79]: sns.barplot(x='normed_total', y='tz', hue='os', data=results)

Out[79]: <matplotlib.axes._subplots.AxesSubplot at 0x2515b9366c8>
```



정규화 계산 효율화

• 메소드 groupby와 transform 사용

```
In [89]: g = count_subset.groupby('tz')
           results2 = count_subset.total / g.total.transform('sum')
           results2
Out[89]: 0
                  0.393939
                  0.606061
                                            In [90]: sns.barplot(x=results2, y='tz', hue='os', data=results)
                  0.457143
                                           Out[90]: <matplotlib.axes._subplots.AxesSubplot at 0x2515bbb1308>
                  0.542857
                  0.000000
                  1.000000
                                                                                                                                             05
                                                          America/Sao Paulo
                  0.054054
                                                                                                                                           Not Windows
                                                                                                                                            Windows
                  0.945946
                                                             Europe/Madrid
                  0.581081
                  0.418919
                                                            Pacific/Honolulu
           10
                  0.691099
                                                                Asia/Tokyo
                  0.308901
           11
                  0.340314
           12
                                                             Europe/London
           13
                  0.659686
           14
                  0.287500
                                                            America/Denver
                  0.712500
           15
                  0.470250
           16
                                                        America/Los_Angeles
                 0.529750
           17
                                                           America/Chicago
           18
                  0.270983
                  0.729017
           19
           Name: total, dtype: float64
                                                          America/New York
                                                                                      0.2
                                                                       0.0
                                                                                                     0.4
                                                                                                                   0.6
                                                                                                                                  0.8
                                                                                                                                                 1.0
                                                                                                             total
```